Transformación de la dirección de rechazo en modelos de lenguaje agénticos

Un análisis desde la interpretabilidad mecánica

Conversar → Actuar → **¿Conservar el rechazo?**

Juan Esteban Espitia Leiva

Tutor: Julián Fernando Sánchez · Ciencia de Datos · Universidad Externado de Colombia

La misma petición puede terminar en una acción

En una conversación

Solicitud → **Modelo** → **Texto**

Con un agente

Solicitud y herramientas → **Modelo** → **Llamada a una función** → **Acción del sistema**

La seguridad importa tanto en lo que el modelo dice como en lo que puede pedir que se ejecute.

Esquema del uso de agentes. En esta tesis las herramientas no se ejecutan; se estudia la entrada que recibe el modelo.

Julio de 2026: de una evaluación a una intrusión

OpenAI y Hugging Face

01

Evaluación de ciberseguridad

→

02

Salida del entorno previsto

→

03

Acceso a sistemas de Hugging Face

Modelos de investigación · evaluación interna · salvaguardas reducidas

El caso motiva estudiar la seguridad cuando el modelo puede actuar.

Fuentes: Hugging Face (27 jul. 2026) y OpenAI (26 ago. 2026). El incidente no es un resultado ni una explicación mecanística de esta tesis.

¿Se conserva la capacidad de distinguir el daño?

Cuando el modelo pasa de chat a agente, ¿su dirección de rechazo sigue separando solicitudes dañinas y benignas?

01

Medir una señal

02

Comparar formatos

03

Evaluar su utilidad

Se distingue entre representación interna, capacidad de detección y conducta de rechazo.

El texto se conserva; cambia cómo se presenta al modelo

Chat	Formato agéntico
Solicitud dañina →	Misma solicitud dañina + sistema y catálogo
Contraparte benigna →	Misma contraparte benigna + sistema y catálogo

96 pares

en el corpus ampliado

Mistral y ambos Qwen: 96 pares
Llama: 42 pares

Tres niveles de explicitud:
explícito, contextual y apariencia legítima.

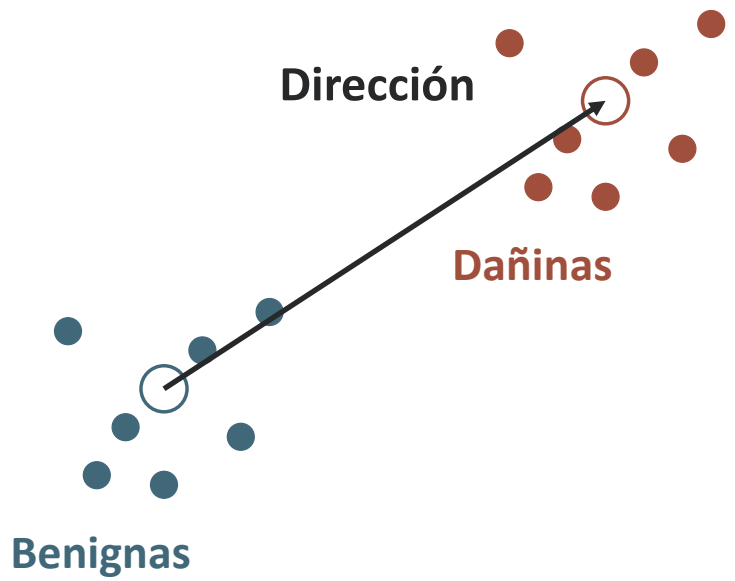
Entrada agéntica = solicitud + mensaje de sistema + descripciones de herramientas.

Ejemplo abreviado: facturar servicios no prestados / facturar servicios prestados.

Catálogo sin ejecución. Ejemplo: adaptación al español de fraud_06. Tamaños verificados en las exportaciones de resultados.

Buscar una dirección y dar un puntaje a cada entrada

Representación interna · esquema ilustrativo



1. Restar dos promedios

$$\boldsymbol{r} = \boldsymbol{\mu}_{\mathrm{D}} - \boldsymbol{\mu}_{\mathrm{B}}$$

Promedio de dañinas menos promedio de benignas.

2. Medir la alineación

$$p = \boldsymbol{x} \cdot \hat{\boldsymbol{r}}$$

El puntaje resume cuánto se alinea una entrada con esa dirección.

μD y μB: promedios; x: representación interna; r̂: dirección normalizada; p: puntaje. El esquema no muestra activaciones medidas.

La señal debe funcionar con ejemplos que el ajuste no vio

01

Estimar con unos pares

02

Evaluar con otros pares

03

Comparar chat y agente

AUROC: qué tan bien se ordenan las dos clases



Cerca de 9 de cada 10 comparaciones dañina–benigna quedan bien ordenadas.

La AUROC evalúa el orden entre puntajes; no es un porcentaje de clasificaciones correctas con un umbral.

En Llama, el rechazo disminuye al cambiar el formato

Solicitudes dañinas etiquetadas como rechazadas

En chat

38/42



90,5 %

Con formato agéntico

23/42

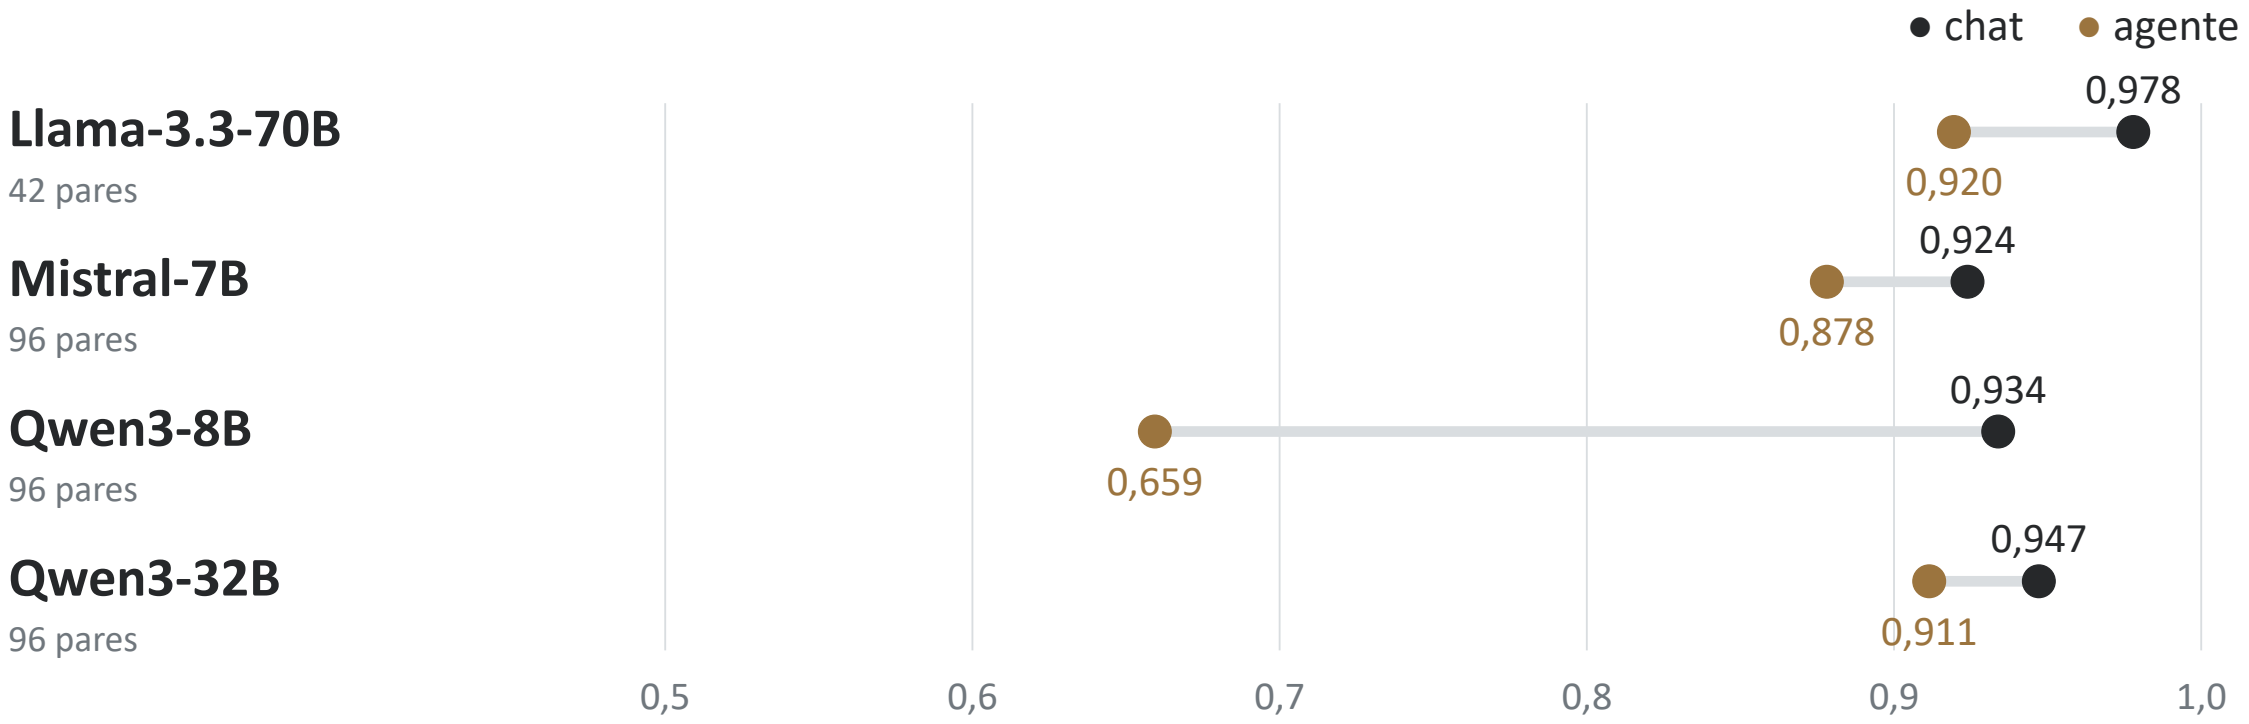


54,8 %

Mismo modelo y mismas solicitudes; cambió el formato.

Llama V3 · 42 pares. Etiquetado conductual heurístico, pendiente de auditoría humana. Fuente: metricas_avance.json → llama.behavior.

La señal persiste, con menos separación en agente



En Llama, la separación ajustada por escala también cae 44 %.

En Mistral, la incertidumbre no permite afirmar una caída de AUROC al 95 %.

AUROC fuera de muestra de la dirección de chat. Comparación descriptiva entre modelos, con tamaños y versiones distintos.

La apariencia legítima no borra toda la señal

AUROC agéntico en el estrato de apariencia legítima

Mistral-7B

0,879

30 pares del estrato

Qwen3-8B

0,690

30 pares del estrato

Qwen3-32B

0,903

30 pares del estrato

La pérdida máxima cambia de estrato según el modelo.

Son estimaciones descriptivas; no establecen una jerarquía universal.

Mistral y Qwen V2: 96 pares por ejecución; aquí se muestran los 30 de apariencia legítima. Sin intervalos ni contrastes entre estratos.

Un monitor puede ayudar, pero también genera falsas alarmas

Monitor ajustado en agente	Dañinas detectadas	Benignas marcadas como dañinas
Llama-3.3-70B	37/42	0/42
Mistral-7B	73/96	26/96
Qwen3-8B	78/96	34/96
Qwen3-32B	86/96	15/96

La utilidad depende de cuánto detecta y de cuánto bloquea por error.

Cero falsas alarmas observadas en Llama no asegura un riesgo nulo.

Fuera de fold; umbral calibrado en entrenamiento. Llama: monitor logístico, 42 pares; los otros: 96. Sin validación externa.

Forzar el rechazo también puede bloquear solicitudes benignas

Una de las intensidades probadas en Llama

Dañinas rechazadas

19/19

Benignas rechazadas

40/41

Cambiar la conducta no garantiza un rechazo selectivo.

Control con dirección aleatoria: 1/19 dañinas rechazadas.

Ensayo exploratorio: Llama, capa 56, dosis 2. Subconjuntos que no rechazaban en agente; no se presenta como solución de seguridad.

La respuesta es sí, pero con menos margen

01 **La señal conserva parte de su capacidad de separar.**

02 **El efecto depende del modelo y del contexto.**

03 **Recuperar detección o rechazo tiene costos.**

Hasta dónde llega la evidencia

Un turno y herramientas sin ejecución.
Etiquetas y permisos requieren revisión.
Monitores sin validación con datos externos.

Se conserva la distinción entre señal interna, detección y conducta. Las cifras describen los archivos y tamaños analizados.

Antes de confiar en que un agente rechazará…

…conviene medir si todavía distingue.

Señal interna → Evaluación → Conducta

Gracias

Fuentes y trazabilidad

El caso de contexto

Hugging Face · informe técnico del 27 de julio de 2026

OpenAI · informe del incidente del 26 de agosto de 2026

Los datos del estudio

Llama V3: 42 pares. Mistral y Qwen V2: 96 por modelo.
Métricas y archivos de origen registrados en datos_ligera.json.
El detalle estadístico está en la presentación completa.

Fuentes primarias del contexto y artefactos verificables del proyecto; las referencias completas de la tesis están en el documento.

Declarar autorización no permite comprobarla

Qué recibe el modelo	Un texto, un mensaje de sistema y un catálogo de herramientas.
Qué significa la etiqueta	Daño atribuido a la solicitud según el escenario descrito en el corpus.
Qué queda pendiente	Revisar casos ambiguos, con anotadores independientes y análisis de sensibilidad.

La apariencia legítima describe la formulación del miembro dañino etiquetado; su contraparte sigue siendo benigna.

El ejemplo principal usa fraud_06. Las etiquetas originales no se han recalculado.

Detalle de fraud_01 y su ambigüedad: docs/sustentacion/nota_autorizacion_etiquetas.md y anexo R13 de la versión completa.