Respuesta a las observaciones del tutor

Tesis: *Transformación de la dirección de rechazo en modelos de lenguaje agénticos*

Nota sobre las versiones

Las observaciones se realizaron sobre la versión en PDF de 80 páginas. La versión que aquí se entrega es una revisión posterior en la que el capítulo de métodos y el de resultados fueron reorganizados: la justificación matemática de la posición de lectura se trasladó al capítulo de métodos, las ecuaciones se numeraron, se incorporó un glosario y las corridas de los tres modelos principales pasaron al corpus completo de 96 pares. Por esa razón la numeración de páginas del PDF comentado no coincide con la de esta versión, y la tabla indica, para cada observación, la sección donde quedó atendida. Las referencias de capítulo siguen la numeración de la versión nueva.

#	Pág.	Observación	Estado	Dónde se atendió
1	1	Nota de proceso: avanzar y preparar la presentación con retroalimentación externa.	—	No requiere cambio de texto.
2	2	Resumen por redactar.	**Por redactar**	Preliminares (Resumen).
3	3	Abstract por redactar.	**Por redactar**	Preliminares (Abstract).
4	13	Corrección ortográfica (acentuación de «estas/éstas»).	**Atendido**	Revisión ortográfica puntual.
5	14	La frase que enuncia las «dos dimensiones» resultaba confusa.	**Atendido**	Cap. 1, Pregunta central. Reescrita con mayor claridad.
6	15	Un concepto central debía definirse bien desde el inicio.	**Atendido (rediseño)**	Glosario (define cono de influencia, proyección, AUROC, entre otros).
7	16	Remite a la observación de la pág. 20.	**Atendido**	Atendida junto con las observaciones #9 y #10.
8	25	Aparente contradicción: se afirma que no se ha estudiado la transición chat–agéntico, cuando antes se indica que Pinto sí lo hizo.	**Atendido**	Cap. 2 (Brecha) y Cap. 1 (intro). Se distingue que Pinto estudió la transferencia como *steering* (control del comportamiento), mientras que lo que permanece abierto es el diagnóstico de la capacidad de detección.
9	30	Si el primer objetivo específico dice variar solo las herramientas, ¿por qué se varían también las instrucciones?	**Atendido**	Cap. 1 (Objetivos específicos). Se separan los dos ejes: dentro de cada par solo cambia el formato (herramientas); entre pares, la explicitud estratifica.

continúa en la página siguiente

#	Pág.	Observación	Estado	Dónde se atendió
10	30	Falta especificar si las ramas dañina y benigna reciben el mismo catálogo de herramientas y el mismo mensaje de sistema.	**Atendido**	Cap. 3 (Diseño contrastivo). Se añade como invariante verificado: mismo mensaje de sistema y misma lista de herramientas entre ramas.
11	32	¿Quién redactó los *prompts*, con qué criterios y hubo revisión asistida por modelos?	**Atendido**	Cap. 3 (Diseño contrastivo). Se añade un párrafo con autoría, criterios de inclusión/descarte y la revisión asistida por modelos (anotador auxiliar de control de calidad).
12	36	La afirmación va más allá de lo que mide la proyección: un valor alto no demuestra detección de peligro.	**Atendido**	Cap. 4 (Desplazamiento). Se añade la salvedad de que la proyección es una medida geométrica y su relación con el rechazo se evalúa aparte (AUROC).
13	37	El diseño es pareado, no independiente; se cuestiona el supuesto de independencia.	**Atendido (rediseño)**	Cap. 3 (Inferencia). La significancia se evalúa con una prueba de permutación de signos pareada, que respeta el emparejamiento y no asume independencia.
14	39	No se presentó el procedimiento ni los resultados de PCA.	**En curso**	Cap. 3/4. La corrida de PCA está en ejecución; se incorporarán la varianza explicada del primer componente y su coseno con la dirección de diferencia de medias.
15	40	¿Conviene fortalecer la descripción de la extracción sobre el flujo residual?	**Atendido (rediseño)**	Cap. 3. Se incluye la derivación completa de la posición de lectura (último *token*, cono de influencia) sobre el flujo residual.
16	43	La prueba de signos sí depende de la dirección usada; debía retirarse la afirmación de insensibilidad.	**Atendido**	Cap. 4 (Estabilidad). Se corrige: es insensible a la escala, no a la dirección; el resguardo es que la dirección se estima fuera de muestra.

continúa en la página siguiente

#	Pág.	Observación	Estado	Dónde se atendió
17	50	Que sonda lineal y MLP den resultados cercanos no basta para afirmar equivalencia; además la curva sube y luego baja.	**Atendido (rediseño)**	Cap. 4 (Línea base). La versión nueva no afirma equivalencia (usa solo la sonda lineal) y describe la curva que asciende al bloque intermedio y desciende después.
18	62	¿Los 39 de 42 pares incluyen los 21 con que se seleccionó la capa 52? Requiere explicación.	**En curso**	El pasaje correspondía a la corrida de Llama sobre 42 pares. La réplica sobre el corpus de 96 pares está en ejecución y sustituirá esas cifras; se documentará la selección de capa.
19	70	Conclusiones y recomendaciones por construir.	**Por redactar**	Cap. 5/6 (Conclusiones).
20	77	Material complementario por construir.	**Por redactar**	Anexos.

Resumen del estado

De las veinte observaciones, trece quedan atendidas en esta versión (nueve por edición directa y cuatro resueltas en la reorganización del documento), una no requiere cambios de texto, dos están en curso a la espera de que finalicen las corridas correspondientes (PCA y la réplica de Llama-3.3-70B sobre el corpus completo) y cuatro corresponden a secciones que el autor redactará (resumen, *abstract*, conclusiones y material complementario).