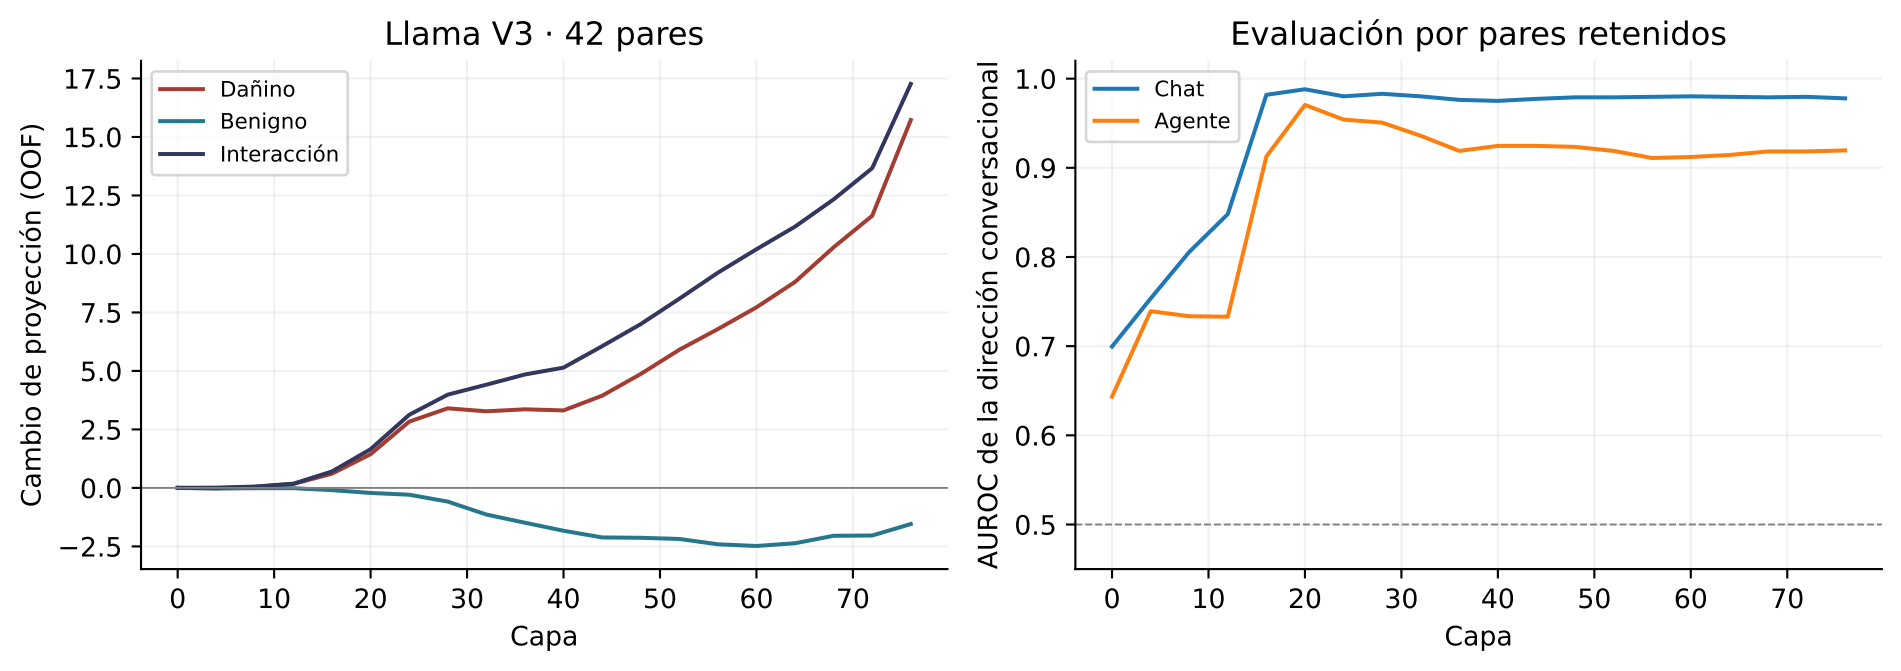
Llama V3 · 42 pares
Dañino
Benigno
Interacción
Cambio de proyección (OOF)
17.5
15.0
12.5
10.0
7.5
5.0
2.5
0.0
−2.5
0
10
20
30
40
50
60
70
Capa
Evaluación por pares retenidos
Chat
Agente
AUROC de la dirección conversacional
1.0
0.9
0.8
0.7
0.6
0.5
0
10
20
30
40
50
60
70
Capa