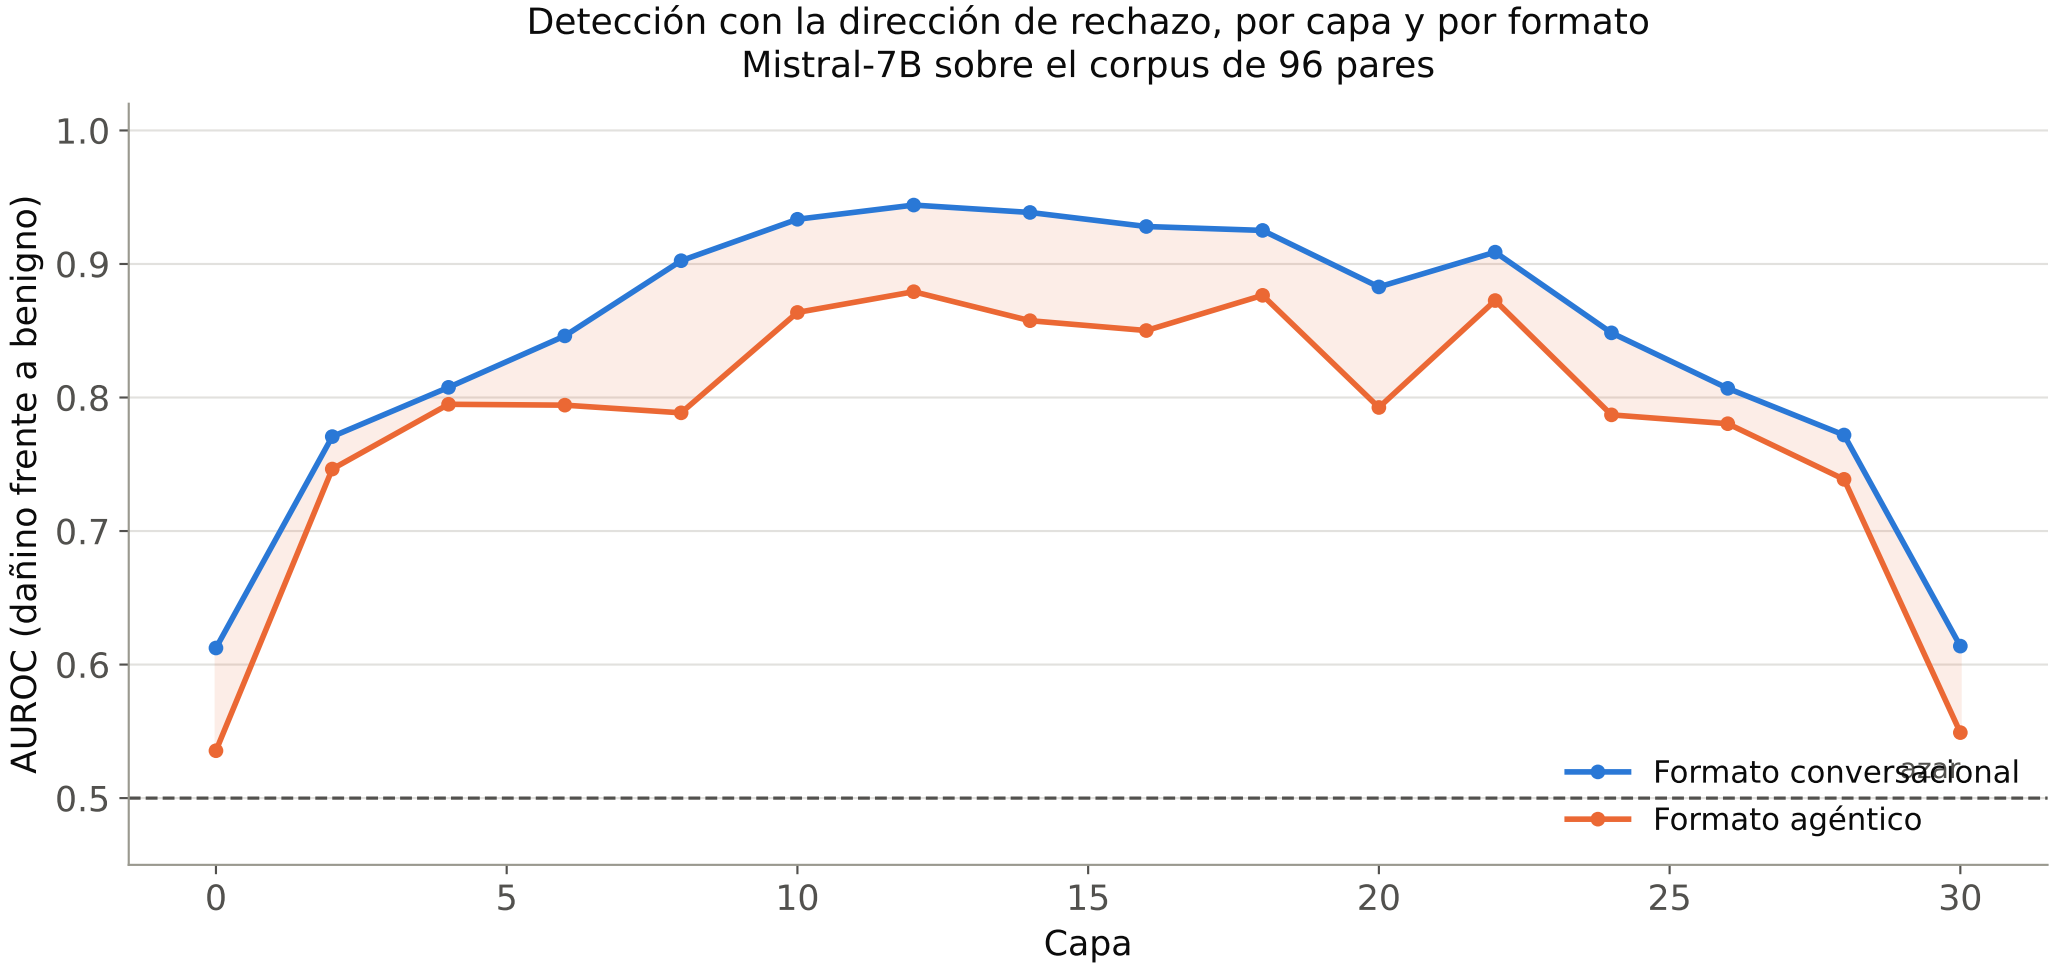
Detección con la dirección de rechazo, por capa y por formato
Mistral-7B sobre el corpus de 96 pares
AUROC (dañino frente a benigno)
1.0
0.9
0.8
0.7
0.6
0.5
0
5
10
15
20
25
30
Capa
Formato conversacional
Formato agéntico