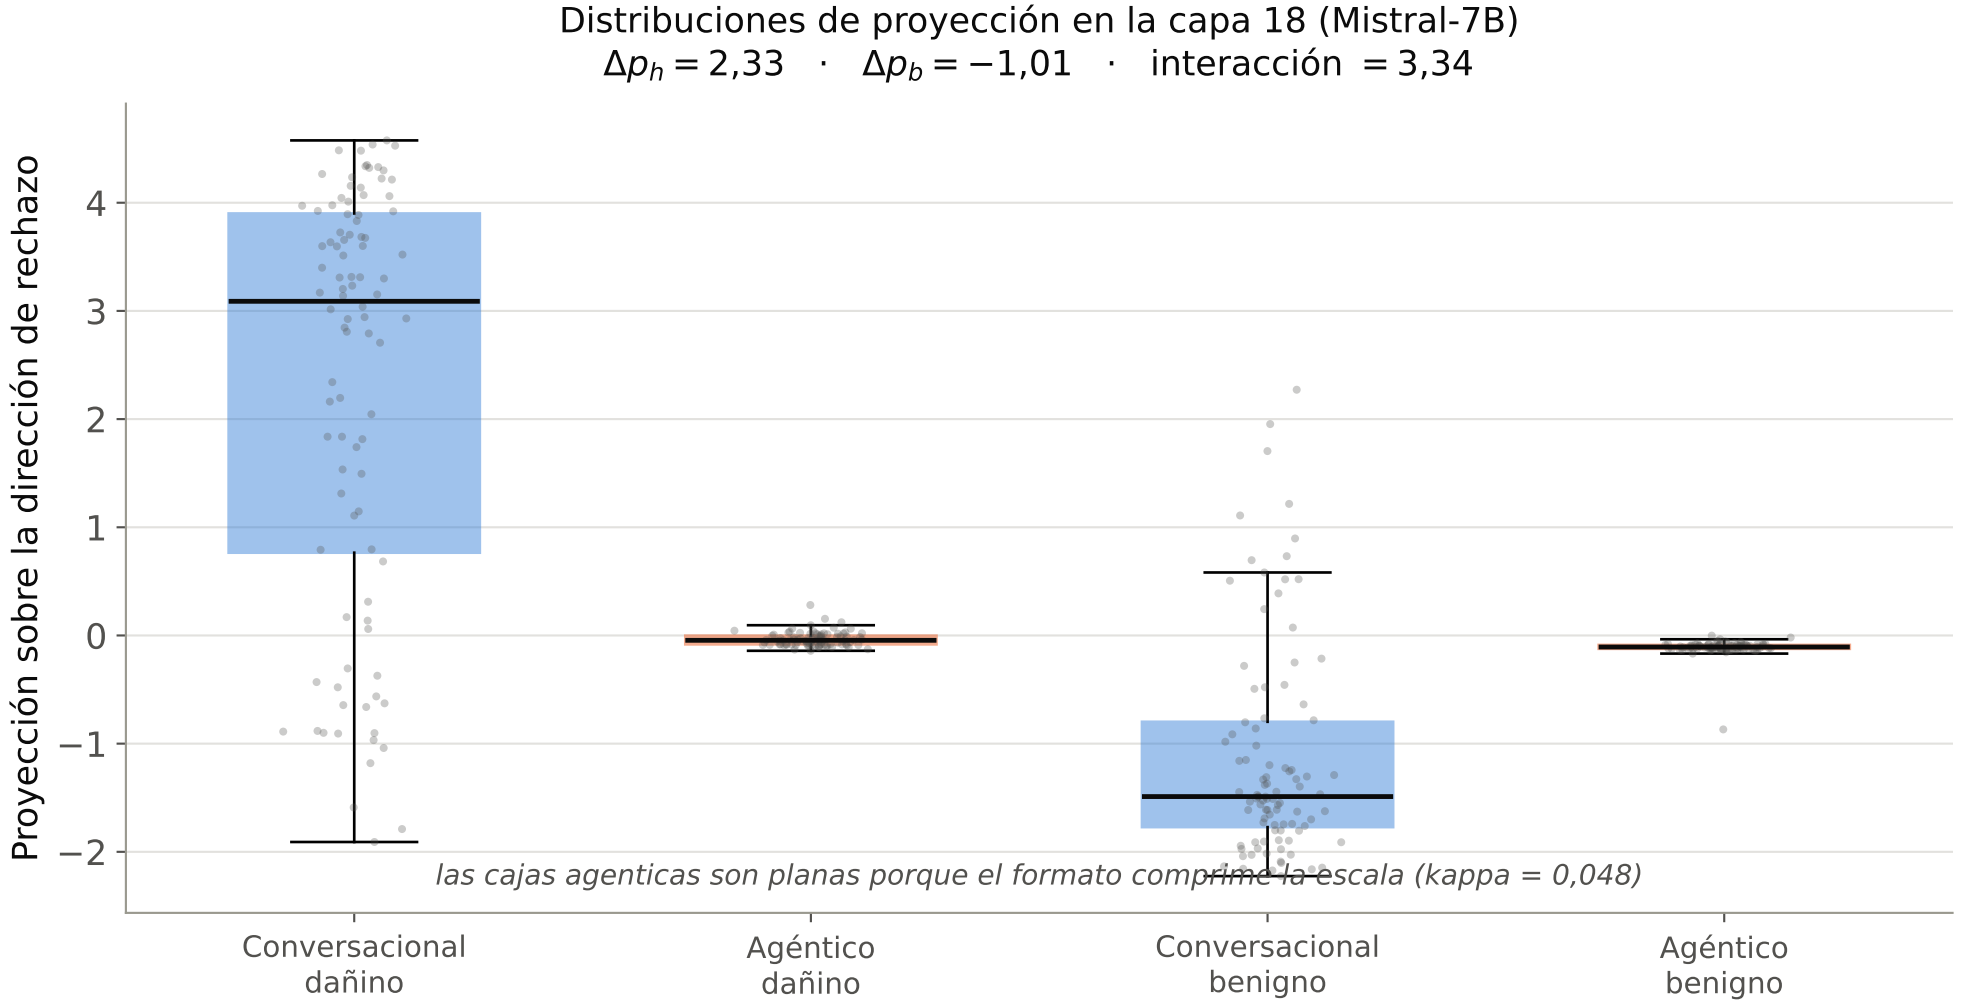
Distribuciones de proyección en la capa 18 (Mistral-7B)
$\Delta p_h = 2{,}33$ · $\Delta p_b = -1{,}01$ · interacción $= 3{,}34$
Proyección sobre la dirección de rechazo
4
3
2
1
0
−1
−2
las cajas agenticas son planas porque el formato comprime la escala (kappa = 0,048)
Conversacional dañino
Agéntico dañino
Conversacional benigno
Agéntico benigno