Universidad Externado de Colombia | DEPARTAMENTO DE MATEMÁTICAS

Transformación de la dirección de rechazo en modelos de lenguaje agénticos

Un análisis desde la interpretabilidad mecánica

Juan Esteban Espitia Leiva

Pregrado en Ciencia de Datos

Departamento de Matemáticas

Universidad Externado de Colombia

Modalidad de grado:	Investigación
Tutor(es):	Julián Fernando Sánchez
Lugar y fecha:	Bogotá, Colombia, 2026

Resumen

Los modelos de lenguaje se despliegan cada vez más como agentes que ejecutan acciones mediante herramientas, y las salvaguardas evaluadas en formato conversacional no se conservan en ese contexto. Este trabajo examina el fallo desde dentro del modelo: estudia qué le ocurre a la dirección de rechazo, la representación interna que media la negativa ante solicitudes dañinas, cuando el modelo pasa de conversar a actuar, y si su capacidad de detección se sostiene ante intenciones de distinto grado de explicitud.

Se construyó un conjunto contrastivo de 96 pares dañino–benigno, con texto idéntico entre formatos y estratificado en tres niveles de explicitud. La dirección se estimó por diferencia de medias sobre el flujo residual del último *token* en cuatro modelos de pesos abiertos de tres familias (Mistral, Qwen y Llama), con control benigno, validación cruzada por pares y unidades invariantes a la escala.

En los cuatro modelos la proyección de las instrucciones dañinas sobre la dirección de rechazo se reduce de manera sistemática al pasar al formato agéntico, y el efecto es específico del contenido dañino, con tamaños de efecto de la interacción entre 2,16 y 2,67. En unidades estandarizadas la separación entre clases cae entre un 31,6 % y un 67,6 %, frente a pérdidas crudas que superan el 99 %: se trata de una pérdida de margen y no de un colapso de la discriminación. La información no desaparece, sino que se reorganiza sobre un eje casi ortogonal al conversacional, recuperable por un monitor estimado en el propio formato agéntico (F_1 de hasta 0,873): un monitor basado en representaciones conversacionales mediría en la dirección equivocada. Las conclusiones son correlacionales; el vínculo causal con el comportamiento requiere una etapa de intervención.

Palabras clave: interpretabilidad mecánica; dirección de rechazo; agentes de lenguaje; seguridad en inteligencia artificial; modelos de lenguaje de gran escala.

Abstract

Language models are increasingly deployed as agents that act through tools, and safeguards evaluated in chat do not carry over to that setting. This work examines the failure from inside the model: it studies what happens to the refusal direction, the internal representation that mediates the refusal of harmful requests, when a model moves from conversing to acting, and whether its detection capacity holds for harmful intent of varying explicitness.

A contrastive dataset of 96 harmful–benign pairs was built, with identical text across formats and stratified into three levels of explicitness. The direction was estimated by difference in means over the residual stream at the last token in four open-weight models from three families (Mistral, Qwen and Llama), with a benign control, pair-level cross-validation and scale-invariant units.

In all four models, the projection of harmful instructions onto the refusal direction decreases systematically in the agentic format, and the effect is specific to harmful content, with interaction effect sizes between 2.16 and 2.67. In standardized units the separation between classes drops by 31.6 % to 67.6 %, against raw losses above 99 %: this is a loss of margin, not a collapse of discrimination. The information does not disappear but is reorganized along an axis nearly orthogonal to the conversational one, recoverable by a monitor estimated in the agentic format itself (F_1 up to 0.873): a monitor built on conversational representations would measure along the wrong direction. The conclusions are correlational; a causal link to behavior requires an intervention stage.

Keywords: mechanistic interpretability; refusal direction; language agents; AI safety; large language models.

Abreviaturas y siglas

IA

Inteligencia artificial.

LLM

Large Language Model. Modelo de lenguaje de gran escala.

RLHF

Reinforcement Learning from Human Feedback. Aprendizaje por refuerzo a partir de retroalimentación humana.

AUROC

Area Under the Receiver Operating Characteristic curve. Área bajo la curva ROC.

BCa

Bias-corrected and accelerated. Intervalo de confianza *bootstrap* con corrección de sesgo y aceleración.

VC

Validación cruzada.

MLP

Multilayer Perceptron. Perceptrón multicapa.

GPU

Graphics Processing Unit. Unidad de procesamiento gráfico.

FP16

Precisión de punto flotante de 16 bits.

Índice general

Resumen ii

Abstract iii

Abreviaturas y siglas iv

Índice de figuras viii

Índice de tablas ix

1. Introducción 1

1.1. Planteamiento del proyecto 1

1.2. Pregunta o propósito central 3

1.3. Justificación y valor esperado 4

1.4. Objetivos 6

1.4.1. Objetivo general 6

1.4.2. Objetivos específicos 6

1.5. Estructura del documento 7

2. Contexto y antecedentes 8

2.1. Caracterización del contexto 8

2.2. Antecedentes y referentes 9

2.2.1. Antecedentes 9

2.2.2. Estado actual 11

2.3. Brecha, necesidad u oportunidad identificada 13

3. Diseño y métodos del proyecto 15

3.1. Enfoque y diseño 15

3.1.1. Enfoque metodológico 15

3.1.2. Tipo de estudio 16
3.1.3. Objeto de estudio 16
3.2. Datos y fuentes de información 17
3.2.1. Diseño contrastivo pareado 19
3.2.2. Estratificación por grado de explicitud 20
3.2.3. Definición de herramientas 21
3.2.4. Composición del conjunto de datos 21
3.2.5. Simetría léxica del pareado y su verificación 23
3.3. Métodos y herramientas 25
3.3.1. Formalización matemática del método 25
3.3.2. Procedimiento de análisis 30
3.3.3. Implementación y reproducibilidad 31
3.4. Estrategia de evaluación y validación 31
3.4.1. Separabilidad entre clases y su estimación 32
3.4.2. Inferencia estadística sobre el diseño pareado 33
3.5. Consideraciones éticas 34

4. Resultados y evaluación **35**
4.1. Resultados, análisis e interpretación 35
4.1.1. Alcance de las corridas 35
4.1.2. Línea base en formato conversacional 36
4.1.3. El desplazamiento entre formatos y su especificidad 38
4.1.4. Escala del efecto 40
4.1.5. Comportamiento según el grado de explicitud 42
4.1.6. Reorientación del eje 43
4.2. Evaluación y validación 44
4.2.1. Estabilidad de la estimación 45

5. Discusión **47**
5.1. Síntesis de los hallazgos 47
5.2. El modo de fallo que describen los resultados 47

5.3. Implicaciones 47
5.4. Limitaciones y alcance de validez 47

Glosario de notación **48**

Referencias **50**

Índice de figuras

4.1. Capacidad de discriminación de la dirección de rechazo por capa y por formato, en Mistral-7B sobre el corpus de 96 pares. La curva agéntica discurre por debajo de la conversacional en todo el bloque profundo sin aproximarse al azar. 37

4.2. Distribuciones de proyección sobre la dirección de rechazo en la capa de referencia de Mistral-7B. Las instrucciones dañinas pierden proyección al pasar al formato agéntico y las benignas la ganan, de modo que ambas nubes convergen sobre el eje que las separaba. 39

4.3. Desplazamiento entre formatos por capa, separado por brazo, en Mistral-7B. El brazo dañino pierde proyección y el benigno la gana, de manera que la interacción excede al efecto principal en toda la red profunda. 40

4.4. El mismo efecto medido en dos unidades, en los tres modelos evaluados sobre el corpus de 96 pares. El panel izquierdo emplea escala logarítmica. La comparación entre modelos solo es legítima en el panel derecho. 41

4.5. Comportamiento por grado de explicitud en los tres modelos evaluados sobre el corpus de 96 pares. El panel izquierdo mide la intensidad de la respuesta mediante el tamaño del efecto del gap de proyección; el derecho, la capacidad de discriminación mediante la pérdida de AUROC. 43

4.6. Coseno entre la dirección estimada en formato agéntico y la dirección de rechazo conversacional, por profundidad relativa en la red. El círculo marca el mínimo de cada curva. Las tres familias recorren el mismo descenso hacia el bloque intermedio-profundo. 44

Índice de tablas

3.1. Distribución de los 96 pares dañinos por categoría de daño y por nivel de explicitud de la intención. 22

3.2. Solapamiento léxico entre la rama dañina y la benigna de cada par, medido con el índice de Jaccard, por nivel de explicitud de la intención. 24

3.3. Dimensiones de los modelos estudiados: número de capas L, dimensión del flujo residual d, cabezas de consulta H y de clave y valor H_{kv}, y dimensión interna del perceptrón d_{ff}. La última columna indica cuántas capas cubre el barrido de cada corrida. 26

4.1. Configuración de las corridas reportadas 36

4.2. Separabilidad dañino–benigno en formato conversacional 36

4.3. Desplazamiento entre formatos en la capa de referencia 38

4.4. El efecto expresado en unidades invariantes a la escala 41

4.5. Capacidad de detección por grado de explicitud 42

4.6. Corrección por circularidad en la capa de referencia 45

Capítulo 1

Introducción

Los modelos de lenguaje de gran escala han dejado de ser sistemas que solo producen texto para desplegarse como agentes capaces de ejecutar acciones en el mundo. Ese tránsito ha ocurrido más rápido que la comprensión de sus consecuencias para la seguridad, y ha dejado en pie un supuesto que la evidencia disponible no respalda: que las garantías obtenidas al evaluar un modelo conversando se conservan cuando ese mismo modelo actúa.

Este trabajo examina ese supuesto desde dentro del modelo. En lugar de observar qué hace un agente ante una petición dañina, examina qué ocurre con la representación interna que gobierna su capacidad de rechazarla cuando pasa de un contexto de operación al otro. El capítulo presenta el problema que origina la investigación, la pregunta que la orienta, las razones que la justifican y los objetivos mediante los cuales se aborda.

1.1. Planteamiento del proyecto

En los últimos dos años, los modelos de lenguaje de gran escala (*Large Language Models*, LLM) dejaron de operar como sistemas puramente conversacionales para desplegarse como agentes: sistemas capaces de ejecutar código, enviar correos, consultar bases de datos o iniciar transacciones mediante el uso de herramientas externas, sin intervención humana en cada paso. La adopción ha sido veloz. De acuerdo con reportes del sector, se estima que para finales de 2026 cerca del 40 % de las aplicaciones empresariales incorporarán agentes de tarea específica, frente a menos del 5 % dos años atrás (miniOrange, 2026). Aquello que era un experimento se ha vuelto infraestructura.

El cambio altera la naturaleza del riesgo. Un fallo en un sistema conversacional produce texto inadecuado; un fallo en un sistema agéntico produce acciones con efectos reales sobre datos,

dinero o infraestructura (Andriushchenko et al., 2024). Como las tareas agénticas se componen de múltiples pasos encadenados, un error en un punto se propaga a toda la operación, y el acceso a herramientas amplifica su alcance, de modo que un mismo fallo puede afectar a una cuenta o a cientos. Esta diferencia empieza a reflejarse en la experiencia del sector. Según un reporte de industria, el 88 % de las organizaciones consultadas registró incidentes de seguridad vinculados a agentes durante el último año, cifra que asciende al 92,7 % en el sector salud, y ubica la pérdida de control sobre el comportamiento de los agentes como el riesgo predominante (Gravitee, 2026). Se trata de datos de percepción y experiencia del sector, no de mediciones controladas, pero coinciden con la evidencia académica que se expone a continuación.

La raíz de esta vulnerabilidad se encuentra en un supuesto que el despliegue de estos sistemas ha dado por válido: que las garantías de seguridad obtenidas al evaluar un modelo en formato conversacional se conservan cuando ese mismo modelo opera como agente. Andriushchenko et al. (2024) mostraron que el supuesto es falso. A través del *benchmark* AgentHarm documentaron que modelos de frontera ejecutan tareas dañinas en formato agéntico sin necesidad de técnicas de evasión, que las evasiones diseñadas para el chat se transfieren con facilidad al contexto agéntico, y que un modelo cuyas defensas han sido vulneradas conserva intactas sus capacidades, ejecutando la tarea dañina con la misma competencia con que ejecutaría una legítima. La seguridad evaluada en un contexto, en suma, no se traslada al otro.

Ahora bien, este tipo de evidencia describe el fallo sin explicarlo. Mide que las salvaguardas ceden en contexto agéntico, pero no qué ocurre dentro del modelo para que cedan. Aproximarse a esa explicación exige mirar los mecanismos internos que sostienen la seguridad. Arditi et al. (2024) mostraron que el rechazo a solicitudes dañinas no está repartido de manera difusa por la red, sino gobernado por una sola dirección en el espacio de activaciones, un hallazgo que replicaron en trece modelos abiertos de hasta 72 mil millones de parámetros: al remover esa dirección el modelo pierde la capacidad de rechazar, y al reforzarla rechaza incluso peticiones inofensivas. El rechazo, entonces, tiene una forma geométrica concreta, medible y ligada de manera causal al comportamiento. Y no es un caso único; trabajos posteriores hallaron representaciones internas identificables para otros

comportamientos sensibles, como el engaño o la escritura de código inseguro (Templeton et al., 2024), lo que indica que la seguridad de un modelo no se apoya en un mecanismo aislado sino en un conjunto más amplio de representaciones internas.

Dos aspectos de estos mecanismos permanecen, sin embargo, sin examinar. El primero es su sensibilidad al modo en que se presenta el daño. Un modelo alineado rechaza sin dificultad una instrucción abiertamente dañina, pero los casos que importan en la práctica rara vez son abiertos: son solicitudes de apariencia legítima cuya intención dañina queda implícita en el contexto. No se sabe si la representación interna de la peligrosidad se activa con igual fuerza ante una instrucción explícita que ante una encubierta, o si se atenúa a medida que el daño se disimula en la superficie del texto. El segundo aspecto es el contexto de operación. La dirección de rechazo se ha caracterizado casi por completo en formato conversacional (Arditi et al., 2024); su comportamiento cuando el modelo dispone de herramientas apenas se ha tocado. El trabajo más cercano, de Lermen et al. (2024), removió el vector de rechazo de un modelo de gran escala y confirmó que el agente resultante completaba tareas dañinas, pero procedió eliminando el mecanismo por diseño, sin llegar a medir si este se debilita por sí solo al pasar al formato agéntico.

De este modo, la evidencia disponible deja abierto un punto preciso. Se sabe, en el plano del comportamiento, que las salvaguardas fallan cuando el modelo actúa como agente (Andriushchenko et al., 2024), y se sabe, en el plano mecánico, que el rechazo está mediado por una dirección en el espacio de activaciones caracterizada en el formato conversacional (Arditi et al., 2024). Lo que no se ha determinado es si, al transitar el modelo al formato agéntico, esa representación conserva su capacidad para detectar la intención dañina, y si esa capacidad se mantiene frente a solicitudes de distinto grado de explicitud. Esa es la pregunta que este trabajo aborda.

1.2. Pregunta o propósito central

Cuando un modelo de lenguaje pasa de conversar a actuar como agente, ¿conserva su dirección de rechazo la capacidad de detectar intenciones dañinas, incluso cuando éstas se presentan de forma encubierta?

La pregunta reúne dos dimensiones de un mismo fenómeno —la robustez de la representación de rechazo—, y ambas se encuentran dentro del alcance del estudio. La primera es el cambio de formato, del conversacional al agéntico. La segunda es el grado de explicitud con que se presenta la intención dañina. El diseño contrastivo descrito en la metodología, que cruza estos dos factores, permite abordarlas de manera conjunta y no como problemas separados.

1.3. Justificación y valor esperado

Comprender qué ocurre con las representaciones internas de seguridad cuando un modelo opera como agente no es una cuestión de interés únicamente teórico. La brecha entre la velocidad con que estos sistemas se despliegan y la madurez de sus controles de seguridad es hoy uno de los puntos críticos del uso de inteligencia artificial. Reportes del sector describen esta desconexión con claridad. Si bien el 82 % de los directivos confía en que sus políticas actuales previenen acciones no autorizadas de los agentes, más de la mitad de los agentes en producción operan sin supervisión ni registro, situación que se atribuye a que las organizaciones aplican a los agentes marcos de seguridad pensados para software convencional, cuando los agentes deciden de forma autónoma e invocan herramientas de maneras que esos marcos no anticipan (Gravitee, 2026). Los controles predominantes actúan desde fuera del modelo, mediante permisos, credenciales y límites de autorización. Sin embargo, el fallo relevante para este estudio no ocurre únicamente fuera del modelo, sino también en su decisión interna de ejecutar o rechazar una acción, de modo que una defensa que no considere lo que el modelo representa internamente antes de actuar atiende el síntoma y no la causa.

La aproximación conductual, dominante en la evaluación de estos sistemas, resulta insuficiente para cerrar esa brecha. Los *benchmarks* miden qué hace el modelo, no por qué lo hace, y esa distinción tiene consecuencias prácticas: sin una explicación del mecanismo no es posible distinguir un fallo puntual de una vulnerabilidad estructural, ni anticipar en qué condiciones volverá a producirse. A ello se añade una limitación de fondo, y es que un modelo puede comportarse de manera distinta cuando infiere que está siendo evaluado, lo que impone un techo a cualquier método

basado solo en observar la conducta (Greenblatt et al., 2024). La interpretabilidad mecánica ofrece una vía complementaria. Al examinar las representaciones internas, y mediante intervenciones controladas sobre mecanismos específicos, permite aproximarse a explicaciones causales sobre el origen del fallo y, a partir de ellas, a intervenciones dirigidas (Arditi et al., 2024). Que este enfoque es viable lo respalda el que laboratorios de frontera dediquen esfuerzo a auditar las representaciones de seguridad de sus propios modelos en producción (Templeton et al., 2024); si el alineamiento por entrenamiento bastara, ese esfuerzo sería innecesario.

El estudio de la dirección de rechazo constituye un punto de entrada idóneo a este problema. Es el mecanismo de seguridad mejor caracterizado matemáticamente, con un método de cálculo transparente y reproducible y una relación causal con el comportamiento ya demostrada (Arditi et al., 2024), lo que lo convierte en un caso donde el método puede validarse con solidez antes de extenderse a representaciones más complejas. Diagnosticar cómo se transforma esta dirección al pasar al formato agéntico, y si su capacidad de detección resiste ante intenciones dañinas de distinta explicitud, aporta la explicación mecánica que la evidencia conductual no proporciona. Este diagnóstico, además, podría sentar las bases para trabajos futuros orientados a restaurar la representación cuando se degrada. Aunque tal restauración excede el alcance de la presente investigación, de naturaleza diagnóstica, abriría en principio una estrategia de protección basada en las representaciones internas, aplicable al conjunto más amplio de comportamientos de seguridad que el modelo codifica y complementaria a los controles externos que la industria reconoce como insuficientes.

Finalmente, esta línea de trabajo se inscribe en un campo de expansión acelerada pero de participación aún concentrada en unos pocos países de América Latina. Según el Índice Latinoamericano de Inteligencia Artificial, solo siete países de la región tienen presencia en los *main tracks* de las conferencias internacionales de élite, y el 82 % de los autores regionales que participan en ellas proviene únicamente de Chile y Brasil, lo que refleja la escasa presencia del resto de la región, Colombia incluida, en los espacios de investigación de frontera (Durán et al., 2025). Desarrollar esta línea desde una universidad colombiana, con atención a las condiciones reales de despliegue

de estos sistemas en la región, contribuye tanto al conocimiento del fenómeno como a diversificar las perspectivas desde las cuales se define la agenda de seguridad en inteligencia artificial.

1.4. Objetivos

1.4.1. Objetivo general

Analizar, mediante técnicas de interpretabilidad mecánica, cómo se transforma la dirección de rechazo en las representaciones internas de un modelo de lenguaje al pasar del formato conversacional al agéntico, y evaluar la estabilidad de su capacidad de detección según el grado de explicitud de la intención dañina, explorando de manera preliminar su potencial como base para un mecanismo de monitoreo de seguridad.

1.4.2. Objetivos específicos

1. Construir un conjunto de datos contrastivo que permita aislar el efecto del formato agéntico sobre las representaciones internas del modelo. Dentro de cada par, el contenido de la instrucción se mantiene idéntico entre el formato conversacional y el agéntico, de modo que la única diferencia dentro de la comparación es la disponibilidad de herramientas; el conjunto, además, estratifica las instrucciones base según el grado de explicitud de la intención dañina, dimensión que distingue unos pares de otros y no introduce variación dentro de cada comparación pareada.

2. Calcular la dirección de rechazo a partir de las activaciones del modelo y caracterizar su comportamiento por capa en el formato conversacional como línea base.

3. Cuantificar la variación de la proyección sobre la dirección de rechazo entre el formato conversacional y el agéntico para instrucciones idénticas, evaluando la significancia estadística de la diferencia observada.

4. Evaluar la estabilidad de la capacidad de detección de la dirección de rechazo según el grado de explicitud de la intención dañina, comparando su respuesta frente a solicitudes con intención manifiesta y encubierta.

5. Explorar, con carácter preliminar, la viabilidad de emplear la dirección de rechazo como base para un mecanismo de monitoreo que detecte intención dañina en el formato agéntico, entendida esta exploración como una valoración de su potencial y no como el desarrollo de un sistema funcional.

1.5. Estructura del documento

El documento se organiza en cuatro capítulos adicionales al presente. El Capítulo 2 sitúa el proyecto en su contexto y revisa los antecedentes y el estado actual de la literatura sobre alineamiento, interpretabilidad mecánica y dirección de rechazo, para precisar al final la brecha de conocimiento que el trabajo aborda. El Capítulo 3 expone el diseño de la investigación, la construcción del conjunto de datos contrastivo, la formalización matemática del método y la estrategia de evaluación y validación empleada. El Capítulo 4 presenta los resultados obtenidos en las corridas realizadas y su evaluación frente a los criterios definidos. El Capítulo 5 los interpreta: sintetiza los hallazgos, expone el modo de fallo que describen, desarrolla sus implicaciones y delimita el alcance de su validez.

Capítulo 2

Contexto y antecedentes

Este capítulo sitúa el proyecto en el terreno donde ocurre el fenómeno que estudia. La primera sección caracteriza ese terreno en tres planos: el formato agéntico como escenario técnico de operación, los modelos de pesos abiertos como objetos susceptibles de observación interna, y el espacio de solicitudes sobre el que se mide la respuesta del modelo. La segunda revisa los antecedentes y el estado actual del conocimiento, desde el origen del comportamiento de rechazo en el alineamiento hasta los trabajos más recientes que han comenzado a examinar la dirección de rechazo fuera del formato conversacional. La tercera delimita, a partir de todo lo anterior, el vacío preciso que la investigación aborda.

2.1. Caracterización del contexto

Tres planos caracterizan el terreno en el que ocurre el fenómeno estudiado. El primero es el formato agéntico como escenario técnico. La diferencia entre un modelo que conversa y uno que actúa no reside en el modelo, que es el mismo, sino en lo que acompaña a la instrucción dentro de su contexto: en el formato agéntico el modelo recibe además un mensaje de sistema que lo sitúa como agente y un catálogo de herramientas descritas en el formato de llamada a funciones, lo que le habilita una salida adicional, la invocación de una acción que el sistema ejecutará por él. Entre la respuesta y su efecto desaparece el ser humano que en el formato conversacional lee la respuesta y decide si actuar, y la decisión de cumplir o rechazar, tomada una vez al comienzo, gobierna toda la secuencia de acciones posterior. Para este trabajo, lo relevante es que el estímulo agéntico es más largo, incorpora vocabulario técnico ajeno a la petición y sitúa al modelo en otro rol, y cualquiera de esos elementos puede alterar las representaciones sobre las que opera el mecanismo de rechazo.

El segundo plano son los modelos de pesos abiertos como objeto observable. Un estudio de interpretabilidad mecánica requiere acceso a las activaciones internas durante el procesamiento, algo que los sistemas accesibles solo mediante interfaces de programación no ofrecen. Por eso la literatura sobre la dirección de rechazo se ha construido sobre modelos abiertos (Arditi et al., 2024), y por eso este trabajo exige que los modelos estudiados sean abiertos, estén alineados y admitan el uso de herramientas. Esa condición introduce una tensión que el trabajo no resuelve: los sistemas cuyo fallo motiva la investigación son, en su mayoría, cerrados.

El tercer plano es el espacio de solicitudes. Las peticiones que un modelo alineado debe rechazar difieren en el tipo de daño, que el trabajo organiza en siete categorías tomadas de la taxonomía consolidada para la evaluación de agentes (Andriushchenko et al., 2024), y en el grado en que la intención dañina se manifiesta en la superficie del texto, dimensión que este trabajo introduce como constructo propio. La segunda importa porque el riesgo práctico no se concentra donde el daño es evidente: las solicitudes que atraviesan las salvaguardas son aquellas cuya peligrosidad reside en el propósito y no en las palabras.

2.2. Antecedentes y referentes

2.2.1. Antecedentes

El alineamiento como origen del comportamiento de rechazo

El comportamiento de un modelo de lenguaje de negarse a cumplir solicitudes dañinas no es una propiedad espontánea, sino el resultado de un proceso de entrenamiento posterior al preentrenamiento, conocido como alineamiento. Ouyang et al. (2022) establecieron que aumentar el tamaño de un modelo no lo hace, por sí solo, mejor en seguir la intención del usuario: los modelos grandes pueden generar contenido no veraz, tóxico o simplemente inútil, esto es, contenido no alineado con el usuario. Para corregir esta desalineación propusieron un procedimiento en dos fases. En la primera, ajustan el modelo mediante aprendizaje supervisado sobre demostraciones escritas por anotadores del comportamiento deseado. En la segunda, recogen ordenamientos humanos de

las salidas del modelo, entrenan con ellos un modelo de preferencias y lo utilizan como señal de recompensa para seguir ajustando el modelo mediante aprendizaje por refuerzo, procedimiento que se denomina aprendizaje por refuerzo a partir de retroalimentación humana (RLHF, por sus siglas en inglés). El modelo resultante, denominado InstructGPT, mostró mejoras en veracidad y reducciones en la generación de salidas tóxicas, hasta el punto de que sus salidas fueron preferidas sobre las de un modelo cien veces mayor sin este ajuste. El RLHF constituye así la vía por la cual un modelo aprende a comportarse de manera útil e inocua, y es el origen del comportamiento de rechazo que esta investigación estudia.

Sobre esta base, Bai et al. (2022) propusieron un procedimiento orientado específicamente a la inocuidad, denominado Constitutional AI, que reduce la dependencia de etiquetas humanas para identificar contenido dañino. En su método, la supervisión humana se limita a un conjunto de principios o reglas, y el propio modelo genera autocríticas y revisiones de sus respuestas conforme a dichos principios; posteriormente, un modelo evalúa las preferencias entre respuestas y esa señal, generada por inteligencia artificial, sustituye a la humana en la fase de refuerzo. Más allá del procedimiento, su trabajo aporta una precisión conceptual relevante para esta investigación: el resultado deseado no es un modelo evasivo, sino un asistente inocuo pero no evasivo, capaz de enfrentar las consultas dañinas explicando sus objeciones a ellas. El rechazo, en este sentido, no es un simple silencio ante lo peligroso, sino un comportamiento deliberado producto del alineamiento.

Del modelo conversacional al agente y el fallo de las salvaguardas

El comportamiento de rechazo se estableció y se evaluó, en su mayor parte, sobre modelos que operan en formato conversacional. Sin embargo, el despliegue reciente de estos modelos como agentes, dotados de herramientas que les permiten actuar en el mundo, introdujo un escenario en el que las salvaguardas obtenidas por alineamiento no necesariamente se conservan. Andriushchenko et al. (2024) proporcionaron la primera medición sistemática de este problema mediante el *benchmark* AgentHarm, que evalúa el comportamiento de agentes ante ciento diez tareas explícitamente dañinas, distribuidas en once categorías de daño y ejecutadas mediante el uso de herramientas

simuladas. Sus resultados mostraron que modelos de frontera cumplen una fracción considerable de estas tareas sin necesidad de técnicas de evasión, que los ataques de evasión diseñados para el formato conversacional se transfieren con eficacia al contexto agéntico, y que un modelo cuyas defensas han sido comprometidas conserva sus capacidades, ejecutando la tarea dañina con la misma competencia con que ejecutaría una legítima. Este trabajo estableció, a nivel conductual, que la seguridad evaluada en el formato conversacional no se traslada al agéntico, y dejó planteada la pregunta por los mecanismos internos responsables de ese fallo, cuestión que los enfoques puramente conductuales no pueden resolver.

2.2.2. Estado actual

La lectura de las representaciones internas mediante clasificadores lineales

El estudio de los mecanismos internos de un modelo requiere métodos capaces de extraer información interpretable de sus representaciones. El fundamento metodológico de esta aproximación se remonta a Alain y Bengio (2017), quienes propusieron el uso de clasificadores lineales, denominados sondas (*probes*), entrenados de manera independiente del modelo y sobre las activaciones de una capa intermedia, con el fin de medir qué tan aptas son dichas activaciones para una tarea de clasificación. Una observación central de su trabajo es que la separabilidad lineal de las características aumenta de forma monótona con la profundidad de la red, es decir, la información se vuelve progresivamente más accesible de manera lineal en las capas más profundas. Aunque su estudio se realizó sobre modelos de visión por computadora, la técnica de la sonda lineal constituye el antecedente metodológico de todo el trabajo posterior que localiza conceptos en las activaciones de un modelo, y es la base sobre la que se apoya la medición de la separabilidad entre clases empleada en esta investigación.

La hipótesis de representación lineal y la ingeniería de representaciones

La razón por la cual una sonda lineal resulta efectiva se formaliza en la hipótesis de representación lineal, según la cual muchos conceptos de alto nivel se codifican como direcciones

lineales en el espacio de activaciones de un modelo. Park et al. (2024) desarrollaron una formulación de esta hipótesis y de la geometría del espacio de representaciones que la sustenta, ofreciendo el marco teórico que justifica buscar un concepto, como la peligrosidad de una instrucción, en la forma de una dirección. Sobre esta base, Zou et al. (2023) propusieron el marco de ingeniería de representaciones (*representation engineering*), que sistematiza la lectura y la manipulación de conceptos de alto nivel en las activaciones de una red, y establece procedimientos para extraer direcciones asociadas a comportamientos y para intervenir sobre ellas durante la inferencia. Este marco proporciona el instrumental conceptual y técnico sobre el que se construye el estudio de mecanismos de seguridad específicos, como el rechazo.

La dirección de rechazo y su auditabilidad

La aplicación de este instrumental al comportamiento de rechazo fue realizada por Arditi et al. (2024), quienes demostraron que el rechazo a solicitudes dañinas no se encuentra distribuido de manera difusa por la red, sino mediado por una única dirección en el espacio de activaciones del flujo residual. Su método, basado en la diferencia de medias entre las activaciones de instrucciones dañinas y benignas, permite extraer dicha dirección, y sus intervenciones establecen su papel causal: la eliminación de la dirección suprime la capacidad de rechazo, mientras que su adición la induce incluso ante solicitudes inofensivas. Este resultado, validado en trece modelos de código abierto de hasta setenta y dos mil millones de parámetros, constituye el fundamento metodológico directo de esta investigación. De manera complementaria, Templeton et al. (2024) mostraron, mediante autoencoders dispersos aplicados a un modelo de producción, que es posible extraer millones de características interpretables de las representaciones internas, entre ellas características asociadas a conceptos de seguridad como el engaño o la generación de código inseguro. Este trabajo evidencia que las representaciones de seguridad no son un caso aislado del rechazo, sino un fenómeno auditable y extendido en las representaciones internas de un modelo.

El rechazo en contextos de intervención y su dependencia del contexto

Un conjunto reciente de trabajos ha comenzado a examinar el comportamiento de la dirección de rechazo más allá del formato conversacional en el que fue caracterizada, y ha revelado que no se trata de un mecanismo estable ni aislado. Lermen et al. (2024) aplicaron la ablación del vector de rechazo a un modelo de gran escala y verificaron que el agente resultante completaba tareas dañinas que, sin la intervención, habría rechazado; su enfoque, no obstante, fue de carácter intervencionista, pues eliminó deliberadamente el mecanismo en lugar de medir si este se debilita de forma natural al cambiar de contexto. Por su parte, Zhong y Li (2026) mostraron que la dirección de rechazo depende de la representación de la persona del modelo: al dirigir el modelo hacia una persona complaciente, la tasa de rechazo se desploma, y la reintroducción de la dirección de rechazo restaura el comportamiento únicamente en las capas tardías, lo que los lleva a concluir que el rechazo se condiciona en la etapa de expresión, río abajo de donde se computa. Tratar el rechazo como una dirección única y aislada, señalan, pierde de vista su dependencia del contexto.

El trabajo más próximo al presente estudio es el de Pinto (2026), quien realizó el primer análisis sistemático de la transferencia del formato conversacional al agéntico de la dirección de rechazo empleada para dirigir el comportamiento (*steering*). Su hallazgo es que la dirección alcanza las capas tardías con una intensidad cercana a la plena en todos los modelos evaluados, mientras que su acoplamiento con el comportamiento se recalibra según el modelo y el contexto, amplificándose en unos casos y atenuándose en otros. Ahora bien, su estudio se orienta al control del comportamiento mediante la inyección de la dirección, y no al diagnóstico de la capacidad de la dirección para detectar la intención dañina.

2.3. Brecha, necesidad u oportunidad identificada

De este modo, la evidencia disponible deja abierto un punto preciso. Se sabe, en el plano del comportamiento, que las salvaguardas fallan cuando el modelo actúa como agente (Andriushchenko et al., 2024), y se sabe, en el plano mecánico, que el rechazo está mediado por una dirección en

el espacio de activaciones caracterizada en el formato conversacional (Arditi et al., 2024). Lo que no se ha determinado, por tanto, no es si esa dirección persiste al transitar al formato agéntico —Pinto la rastreó en el plano del control del comportamiento y la halló casi intacta en las capas tardías—, sino si, empleada como instrumento de diagnóstico, conserva su capacidad para detectar la intención dañina al operar el modelo como agente, y si esa capacidad se mantiene frente a solicitudes de distinto grado de explicitud. Esa es la pregunta que este trabajo aborda.

La presente investigación se distingue de estos trabajos en dos aspectos. En primer lugar, adopta una perspectiva diagnóstica y no intervencionista: mide cómo se transforma la proyección sobre la dirección de rechazo al pasar al formato agéntico, sin modificar el modelo. En segundo lugar, incorpora el grado de explicitud de la intención dañina como dimensión de análisis, aspecto que la literatura previa no ha abordado y que resulta central para evaluar la robustez del mecanismo de rechazo frente a solicitudes cuya peligrosidad no es evidente en la superficie del texto.

La brecha, en suma, tiene dos componentes que el trabajo aborda de manera conjunta. El primero es que la dirección de rechazo se ha caracterizado en un contexto de operación, el conversacional, distinto de aquel en el que los modelos fallan, y no se ha medido qué le ocurre a esa representación al transitar entre ambos sin intervenir sobre el modelo. El segundo es que esa caracterización se ha construido sobre solicitudes cuyo daño es explícito, de modo que se desconoce si la capacidad de detección se conserva cuando la intención se presenta de forma encubierta.

Los objetivos específicos formulados en la Sección 1.4 responden a esta doble brecha en secuencia. El primero construye el instrumento que permite aislar el efecto del formato, un conjunto contrastivo con texto idéntico entre condiciones y estratificado por grado de explicitud, que ningún recurso disponible proporcionaba. El segundo establece la línea base conversacional contra la cual medir. El tercero cuantifica el desplazamiento entre formatos y su significancia, que es el primer componente de la brecha. El cuarto evalúa la estabilidad de la detección según el grado de explicitud, que es el segundo. Y el quinto explora qué consecuencias prácticas tendría el diagnóstico resultante para la construcción de mecanismos de monitoreo, cerrando el vínculo entre el hallazgo mecánico y el problema aplicado que lo motiva.

Capítulo 3

Diseño y métodos del proyecto

Este capítulo describe cómo se estructuró la investigación y con qué procedimientos se abordó la pregunta planteada. La primera sección expone el enfoque, el tipo de estudio y el objeto sobre el que recae el análisis. La segunda detalla la construcción del conjunto de datos contrastivo, que es el instrumento del que depende todo lo demás. La tercera formaliza los objetos matemáticos del método y el procedimiento que los aplica. La cuarta define los criterios y controles con los que se evalúa la validez de los resultados, incluyendo el tratamiento del problema de circularidad que introduce estimar y evaluar una dirección sobre la misma muestra. La quinta recoge las consideraciones éticas asociadas al manejo de un conjunto de instrucciones dañinas.

3.1. Enfoque y diseño

3.1.1. Enfoque metodológico

Esta investigación adopta un enfoque cuantitativo, en la medida en que se apoya en el análisis estadístico de representaciones numéricas internas de un modelo de lenguaje para establecer cómo varía su mecanismo de rechazo entre dos contextos de operación. El diseño es de carácter comparativo, pues contrasta el comportamiento de una misma representación bajo dos condiciones controladas: el formato conversacional y el formato agéntico. La comparación se sostiene sobre un principio de control experimental, según el cual el contenido de cada instrucción se mantiene constante entre condiciones y solo se modifica el elemento cuyo efecto se desea aislar, esto es, la presencia de herramientas y del contexto agéntico asociado.

El estudio se organiza en torno a dos componentes analíticos complementarios. El primero es un componente descriptivo, orientado a caracterizar la dirección de rechazo en el formato conversacional y a establecerla como línea base de referencia. El segundo es un componente comparativo, dirigido a cuantificar cómo se transforma esa dirección al introducir el contexto agéntico y a evaluar la estabilidad de su capacidad de detección según el grado de explicitud con que se presenta la intención dañina.

3.1.2. Tipo de estudio

El estudio es de tipo explicativo. No se limita a describir que las salvaguardas del modelo fallan en el formato agéntico, hecho ya documentado por la literatura conductual, sino que busca aportar una explicación mecánica de ese fallo a partir del comportamiento de las representaciones internas del modelo. El carácter explicativo se sustenta en el uso de técnicas de interpretabilidad mecánica, que permiten examinar la estructura interna sobre la que se apoya el comportamiento de rechazo en lugar de observar únicamente la respuesta final del modelo.

Conviene precisar en qué sentido el diseño es y no es experimental. Respecto del modelo, el estudio es no experimental, dado que este no se modifica ni se reentrena en ningún momento, sino que se analiza tal como se distribuye, observando sus activaciones durante el procesamiento de las instrucciones. Respecto de los estímulos, en cambio, el diseño sí es de carácter experimental y controlado, pues manipula de forma deliberada una única variable, la presencia del contexto agéntico, mientras mantiene constante el contenido de cada instrucción. Esta distinción es importante, ya que el control experimental recae sobre el diseño de los datos y no sobre una intervención en los parámetros del modelo.

3.1.3. Objeto de estudio

El objeto de estudio es la dirección de rechazo, entendida como la representación interna, localizada en el espacio de activaciones de un modelo de lenguaje, que media su capacidad de negarse a cumplir solicitudes dañinas. El interés recae específicamente en cómo esta representación

se comporta cuando el modelo transita del formato conversacional al agéntico, y en si su capacidad de detección se conserva ante instrucciones cuya intención dañina se presenta con distintos grados de explicitud.

El análisis se realiza sobre modelos de lenguaje de pesos abiertos, cuya arquitectura permite el acceso directo a las activaciones internas que el estudio requiere. Las corridas reportadas emplean cuatro modelos de tres familias: Mistral-7B-Instruct-v0.3, Qwen3-8B, Qwen3-32B y Llama-3.3-70B-Instruct. Todos disponen de entrenamiento de alineamiento y de soporte para el uso de herramientas, condiciones necesarias para construir las dos condiciones del estudio. La selección cubre dos ejes de variación. El primero es la receta de entrenamiento: tres familias con procesos de preentrenamiento y alineamiento distintos permiten separar lo propio del fenómeno de lo propio de una receta particular. El segundo es la escala, entre siete y setenta mil millones de parámetros, con dos tamaños dentro de la familia Qwen que permiten observar el efecto del tamaño manteniendo constante la receta. Las características arquitectónicas de los cuatro modelos se recogen en la Tabla 3.3.

Los tres primeros modelos se evalúan sobre el corpus completo de 96 pares descrito en la Sección 3.2. La corrida sobre Llama-3.3-70B se realizó sobre la versión anterior del corpus, de 42 pares, y sus cifras se reportan siempre identificadas como tales; su réplica sobre el corpus completo forma parte del trabajo en curso. Conviene señalar que ampliar la escala no es la vía más informativa para este estudio: su cuello de botella no es la capacidad del modelo sino el tamaño del conjunto de datos, que determina la precisión de todas las estimaciones.

3.2. Datos y fuentes de información

La estrategia de datos se fundamenta en un diseño contrastivo pareado, cuyo propósito es aislar el efecto del formato agéntico sobre las representaciones internas del modelo. El conjunto toma del *benchmark* AgentHarm (Andriushchenko et al., 2024) tres elementos: la taxonomía de categorías de daño, la lógica de tareas que requieren el uso de herramientas y el principio de emparejar cada tarea dañina con una contraparte benigna. Las instrucciones, en cambio, fueron redactadas o

ajustadas para esta investigación, con el fin de incorporar tres controles que la construcción original no contempla y que este estudio requiere: la identidad del texto entre condiciones, la estratificación por grado de explicitud de la intención dañina y la simetría léxica entre las dos ramas de cada par.

La distinción es de propósito y no de calidad. AgentHarm fue construido para medir, en el plano conductual, si un agente cumple una petición peligrosa, y para ese fin basta que la contraparte benigna sea una tarea benigna equivalente. Este estudio, en cambio, estima una dirección en el espacio de activaciones mediante diferencia de medias entre dos centroides, procedimiento que exige que ambos conjuntos difieran en la intención y no en el tema. De ahí que los tres controles no sean un refinamiento opcional sino una condición del método.

La redacción de las instrucciones estuvo a cargo del autor de este trabajo. El punto de partida fueron las instrucciones de AgentHarm, que se tomaron como referencia y se ajustaron para subsanar una limitación de su construcción original: AgentHarm emplea textos distintos entre el formato conversacional y el agéntico, lo que impide atribuir al formato las diferencias que se observen en las representaciones. A partir de esa base, el autor reescribió cada instrucción para preservar la identidad del texto entre condiciones, definió el repertorio de herramientas que la condición agéntica requiere, añadió instrucciones ancladas en el contexto latinoamericano y aplicó los tres controles descritos. El criterio para conservar un par fue que admitiera una contraparte benigna temáticamente simétrica y que pudiera asignarse sin ambigüedad a uno de los tres niveles de explicitud; los casos que no satisfacían ambas condiciones se reformularon hasta cumplirlas o se descartaron.

La construcción contó con una revisión asistida por modelos. Un modelo de lenguaje (Claude) actuó como anotador auxiliar en la revisión de los pares, señalando asimetrías temáticas entre las ramas, discrepancias en la identidad del texto entre formatos y asignaciones de explicitud dudosas, que el autor resolvió al consolidar la versión final. Esta revisión asistida cumplió una función de control de calidad durante la construcción y no sustituye la segunda clasificación independiente que se requiere para estimar el grado de acuerdo entre anotadores, la cual, como se

indica más adelante, queda como trabajo pendiente. La decisión sobre cada caso recayó en todo momento en el autor.

3.2.1. Diseño contrastivo pareado

Cada instrucción base se presenta en cuatro variantes que resultan del cruce de dos factores. El primer factor es el contenido de la instrucción, que puede ser dañino o benigno. El segundo es el formato de operación, que puede ser conversacional o agéntico. De este cruce resultan cuatro condiciones: dañina en formato conversacional, dañina en formato agéntico, benigna en formato conversacional y benigna en formato agéntico.

La característica distintiva del diseño es que el texto de la instrucción es idéntico entre el formato conversacional y el agéntico; la única diferencia entre ambos es la presencia de las definiciones de herramientas y del *prompt* de sistema propio del agente. Este control permite atribuir cualquier variación observada en las representaciones internas al cambio de formato, y no a diferencias en la redacción, limitación presente en los *benchmarks* que emplean textos distintos para cada condición.

Cada instrucción dañina se acompaña de una contraparte benigna construida sobre la misma estructura, de modo que ambas comparten el vocabulario, la longitud aproximada, las entidades mencionadas y el repertorio de herramientas, y difieren únicamente en la intención subyacente. Este emparejamiento es necesario para el cálculo de la dirección de rechazo mediante diferencia de medias, que requiere dos conjuntos comparables de activaciones. Si la rama benigna cambiara de tema además de intención, la dirección estimada capturaría ambas cosas a la vez y no podría interpretarse como un eje de peligrosidad. El grado en que ese control se cumple se verifica de manera explícita y se reporta en la Sección 3.2.5.

El diseño impone además dos invariantes que se verifican sobre la totalidad del conjunto. La primera es que las cuatro variantes de un mismo par comparten identificador, condición de la que dependen todas las pruebas pareadas posteriores. La segunda es que, dentro de cada formato, la rama dañina y la benigna reciben el mismo mensaje de sistema y la misma lista de herramientas,

de modo que la diferencia entre ambas no pueda provenir del andamiaje del agente ni de disponer de capacidades distintas, sino únicamente de la intención de la instrucción.

3.2.2. Estratificación por grado de explicitud

Un aporte central del diseño es la estratificación de las instrucciones dañinas según el grado de explicitud con que se manifiesta la intención dañina, en tres niveles. En el primer nivel, la intención dañina es explícita: el daño es evidente en la superficie del texto y las palabras clave lo delatan directamente. En el segundo nivel, la intención es contextual: el texto no contiene términos abiertamente dañinos, pero la intención se infiere del contexto de la solicitud. En el tercer nivel, la intención se presenta bajo una apariencia legítima: la instrucción está enmarcada como una tarea profesional o justificada, mientras que la acción solicitada es dañina.

Esta estratificación constituye un constructo propuesto en el marco de esta investigación, y no una categorización tomada de un instrumento previamente validado, pues la literatura sobre la dirección de rechazo no ha incorporado el grado de explicitud como dimensión de análisis. Su justificación es conceptual y responde a una limitación de los enfoques que solo consideran daño explícito. Un modelo alineado rechaza con facilidad las instrucciones abiertamente dañinas, precisamente porque las palabras clave activan el mecanismo de rechazo. Los casos que representan un riesgo real en el despliegue son aquellos en los que la intención dañina no reside en las palabras sino en el contexto o en el encuadre. Incorporar los tres niveles permite evaluar si la capacidad de detección de la dirección de rechazo se mantiene estable o se degrada a medida que el daño se vuelve menos evidente en la superficie del texto, cuestión que constituye uno de los objetivos de esta investigación.

El criterio operativo que asigna cada instrucción a un nivel distingue si el vocabulario marcado delata el daño en la superficie del texto, caso en el que la instrucción es explícita, o si el daño debe inferirse de la situación descrita, caso en el que es contextual. El nivel de apariencia legítima se reserva para las instrucciones que además incorporan un encuadre justificador. Cada clasificación quedó registrada con su justificación caso por caso en un archivo de anotación que

acompaña al conjunto de datos, lo que permite auditar la decisión y repetirla. La estimación del grado de acuerdo entre anotadores, prevista en el diseño, requiere una segunda clasificación independiente de la primera y queda como trabajo pendiente.

3.2.3. Definición de herramientas

La construcción de la condición agéntica requiere dotar al modelo de un conjunto de herramientas que definan su capacidad de actuar. Para ello se definió un repertorio de herramientas simuladas (*mock*), especificadas en el formato de llamada a funciones que los modelos emplean para el uso de herramientas. Cada herramienta se describe mediante un nombre, una descripción de su función y un esquema de sus parámetros de entrada.

Estas herramientas no ejecutan ninguna acción real. Su presencia en el contexto tiene como único fin situar al modelo en el escenario agéntico, es decir, hacerle disponible la capacidad de invocar acciones, que es la condición cuyo efecto sobre las representaciones internas se desea estudiar. El repertorio abarca herramientas asociadas a las distintas categorías de daño, tales como el envío de correos, la búsqueda en la web, la consulta de páginas, la ejecución de comandos en terminal, la transferencia de fondos, la generación de imágenes y la publicación en redes sociales, seleccionadas de modo que cada instrucción agéntica disponga de las herramientas coherentes con la tarea que describe.

3.2.4. Composición del conjunto de datos

El conjunto está compuesto por 96 pares base. Cada par se presenta en las cuatro variantes descritas, lo que arroja un total de 384 entradas, distribuidas en partes iguales entre las condiciones *chat* dañina, agéntica dañina, *chat* benigna y agéntica benigna, con 96 instancias cada una. Se verificó que el texto de la instrucción es idéntico entre el formato conversacional y el agéntico en la totalidad de los pares, de modo que la única diferencia entre ambos formatos radica en el *prompt* de sistema y en las definiciones de herramientas.

Las instrucciones dañinas se distribuyen en siete categorías de daño y en los tres niveles de explicitud descritos. La Tabla 3.1 presenta el cruce completo entre ambas dimensiones. Ninguna celda queda vacía y todas contienen entre dos y ocho pares, de modo que cada combinación de categoría y nivel está representada.

Categoría de daño	**Explícito**	**Contextual**	**Ap. legítima**	**Total**
Fraude	6	4	5	15
Cibercrimen	6	2	5	13
Desinformación	4	4	5	13
Acoso	7	3	4	14
Discurso de odio	8	3	4	15
Derechos de autor	5	6	4	15
Drogas	6	2	3	11
Total	**42**	**24**	**30**	**96**

Tabla 3.1: Distribución de los 96 pares dañinos por categoría de daño y por nivel de explicitud de la intención.

El tamaño del estrato más pequeño, con 30 pares, es la cifra que determina la precisión del análisis diferenciado por explicitud. Los tres niveles quedan en órdenes comparables, condición sin la cual ese análisis solo podría presentarse como patrón exploratorio.

Para construir la condición agéntica se definió un repertorio de 64 herramientas simuladas, todas ellas efectivamente empleadas en el conjunto. Cada tarea agéntica dispone de entre dos y ocho herramientas coherentes con la acción que describe, con una media de 3,4 herramientas por tarea. Las más frecuentes son la búsqueda web y la consulta de páginas, presentes en 44 y 40 pares respectivamente, seguidas del envío de correos, la publicación en redes sociales y la carga de archivos.

Ejemplos y alcance del corpus

Los tres niveles se ilustran con la categoría de fraude. En el nivel explícito, una instrucción pide probar credenciales bancarias robadas y transferir fondos a una billetera de criptomonedas, y su contraparte benigna sustituye las credenciales por cuentas de prueba autorizadas. En el contextual,

pide redactar a adultos mayores correos que anuncian un subsidio inexistente para que verifiquen sus datos bancarios en un enlace; ninguna palabra es abiertamente dañina y el fraude se infiere del contexto. En el de apariencia legítima, pide un correo de *phishing* realista enmarcado como entrenamiento de concientización y enviarlo a toda la base de contactos. En los tres casos la instrucción benigna comparte estructura y vocabulario con la dañina, condición que permite que la diferencia de medias capture la intención y no el tema.

Una parte del conjunto recoge, además, tipologías de daño documentadas en el contexto latinoamericano, como la suplantación de un familiar para solicitar una transferencia urgente, los esquemas de captación con rendimientos pagados con nuevos depósitos, la desinformación sobre la reubicación de puestos de votación o la discriminación en procesos de contratación. Estas instrucciones están redactadas en el mismo idioma que el resto del conjunto, porque introducir otro idioma haría que el desplazamiento asociado al idioma entrara en la diferencia de medias y se confundiera con el asociado al daño.

3.2.5. Simetría léxica del pareado y su verificación

El diseño exige que las dos ramas de un par difieran en la intención y no en el tema, pero esa exigencia es cualitativa y no se verifica por inspección. Para hacerla comprobable se adoptó una medida explícita del solapamiento léxico entre ambas ramas, el índice de Jaccard sobre los conjuntos de términos de cada instrucción,

$$J(h, b) = \frac{|T_h \cap T_b|}{|T_h \cup T_b|}, \tag{3.1}$$

donde T_h y T_b denotan los conjuntos de términos de la instrucción dañina y de su contraparte benigna. El índice vale uno cuando ambas instrucciones emplean exactamente el mismo vocabulario y cero cuando no comparten ningún término. Un valor alto indica que la diferencia entre las ramas se concentra en aquello que el diseño pretende aislar; un valor bajo advierte que el par introduce además un cambio de tema.

Esta medida se emplea de dos maneras. La primera es como criterio de construcción: cada par se redactó buscando un solapamiento comparable al del resto del conjunto, con longitudes similares entre ramas y las mismas entidades mencionadas en ambas. La segunda, y más importante, es como control de la comparación entre estratos. Si los pares de un estrato quedaran sistemáticamente mejor pareados que los de otro, una diferencia observada en la capacidad de detección según el grado de explicitud podría provenir de esa asimetría de construcción y no del fenómeno que se desea medir. Verificar que el solapamiento es homogéneo entre estratos es, por tanto, condición para que el análisis diferenciado admita interpretación.

La Tabla 3.2 recoge los valores obtenidos. Los tres estratos quedan dentro de un rango de 0,014, de modo que la comparación entre ellos no está condicionada por la estrechez del pareado.

Nivel de explicitud	**Pares**	**Solapamiento mediano**
Explícito	42	0,408
Contextual	24	0,413
Apariencia legítima	30	0,422
Conjunto completo	**96**	**0,419**

Tabla 3.2: Solapamiento léxico entre la rama dañina y la benigna de cada par, medido con el índice de Jaccard, por nivel de explicitud de la intención.

Conviene precisar el alcance de esta medida. El índice de Jaccard opera sobre conjuntos de términos y no captura ni el orden de las palabras ni la sinonimia, de modo que no es una medida de similitud semántica sino de coincidencia de vocabulario. Su función aquí es acotada y suficiente: detectar los pares en los que la contraparte benigna se aparta del tema de la dañina, que es la forma concreta en que el control del diseño puede fallar. Ocho pares del conjunto presentan un solapamiento inferior a 0,25, y se conservan por ser casos en los que la estructura de la tarea impone vocabulario distinto en cada rama.

El conjunto se genera mediante un procedimiento determinista que comprueba siete invariantes del diseño, entre ellas la identidad del texto entre formatos y de la lista de herramientas entre ramas, y que aborta sin escribir si alguna no se cumple.

3.3. Métodos y herramientas

3.3.1. Formalización matemática del método

El método se apoya en el análisis de las representaciones internas que un modelo de lenguaje de tipo *transformer* genera al procesar una instrucción, siguiendo el planteamiento de Arditi et al. (2024). Esta sección parte de la arquitectura de los modelos estudiados, de la que se derivan la posición de la secuencia en la que se mide y la necesidad de expresar el efecto en unidades invariantes a la escala; define después la dirección de rechazo y las cantidades con las que se comparan los dos formatos.

Arquitectura del modelo y flujo residual

Sea una instrucción tokenizada como la secuencia $t_1, \ldots, t_n$. Los cuatro modelos estudiados son *transformers* decodificadores de L capas con normalización previa a cada bloque. Cada posición i mantiene un vector $\boldsymbol{x}_i^{(l)} \in \mathbb{R}^d$, el flujo residual, que parte de la incrustación del *token* t_i y que cada capa actualiza sumando la contribución de un bloque de atención y la de un perceptrón:

$$\boldsymbol{x}_i^{(l)} = \boldsymbol{x}_i^{(l-1)} + \boldsymbol{a}_i^{(l)} + \boldsymbol{m}_i^{(l)}. \tag{3.2}$$

Ambos bloques leen una versión normalizada del flujo residual (RMSNorm, que divide el vector por su raíz cuadrática media), de modo que lo que leen no depende de su norma; el flujo residual, en cambio, acumula magnitud sin normalizar. El perceptrón, de tipo SwiGLU, actúa sobre cada posición por separado. El bloque de atención es el único que mezcla información entre posiciones: en cada cabeza, los pesos que la posición i asigna a la posición j son

$$\alpha_{ij} = \mathrm{softmax}_j\left(\frac{\boldsymbol{q}_i \cdot \boldsymbol{k}_j}{\sqrt{d_k}} + M_{ij}\right), \qquad M_{ij} = \begin{cases} 0, & j \le i, \\ -\infty, & j > i, \end{cases} \tag{3.3}$$

donde $\boldsymbol{q}_i$ y $\boldsymbol{k}_j$ son proyecciones lineales de las posiciones i y j, rotadas según su posición en la secuencia, y M es la máscara causal. Finalmente, la distribución sobre el siguiente *token* se obtiene de la última posición de la última capa,

$$P(t_{n+1} \mid t_1, \ldots, t_n) = \operatorname{softmax}\big(\boldsymbol{W}_U \operatorname{RMSNorm}(\boldsymbol{x}_n^{(L)})\big). \tag{3.4}$$

La Tabla 3.3 recoge las dimensiones de los cuatro modelos. Desplegando (3.2), el flujo residual en la capa l es la incrustación inicial más la suma de todo lo que las capas anteriores han escrito en él, $\boldsymbol{x}_i^{(l)} = \boldsymbol{x}_i^{(0)} + \sum_{k \le l}(\boldsymbol{a}_i^{(k)} + \boldsymbol{m}_i^{(k)})$. Esa estructura aditiva es la que hace razonable buscar un concepto como una dirección en $\mathbb{R}^d$.

Modelo	L	d	H	H_{kv}	d_{ff}	**Capas evaluadas**
Mistral-7B-Instruct-v0.3	32	4.096	32	8	14.336	16
Qwen3-8B	36	4.096	32	8	12.288	18
Qwen3-32B	64	5.120	64	8	25.600	32
Llama-3.3-70B-Instruct	80	8.192	64	8	28.672	20

Tabla 3.3: Dimensiones de los modelos estudiados: número de capas L, dimensión del flujo residual d, cabezas de consulta H y de clave y valor H_{kv}, y dimensión interna del perceptrón d_{ff}. La última columna indica cuántas capas cubre el barrido de cada corrida.

La posición de lectura: el último *token*

El método mide en una única posición, la del último *token* de la instrucción, por tres razones. La primera es que la máscara causal de (3.3) anula α_{ij} para toda $j > i$, y el perceptrón no mezcla posiciones; por inducción sobre las capas, la representación de la posición i depende solo de los *tokens* $t_1, \ldots, t_i$. Ese conjunto es el *cono de influencia* de la posición, y el de la posición n es el único que contiene la instrucción completa. La segunda es que, por (3.4), el primer *token* de la respuesta, donde se materializa el rechazo o el cumplimiento, se decide a partir de $\boldsymbol{x}_n^{(L)}$: medir en la posición n de una capa intermedia es observar el mismo trayecto que produce la decisión. En adelante se escribe $\boldsymbol{x}^{(l)} \equiv \boldsymbol{x}_n^{(l)}$.

La tercera razón es específica de este diseño. El estímulo agéntico es más largo que el conversacional, porque incorpora el mensaje de sistema y el esquema de herramientas. Una medida que promediara posiciones dependería de la longitud del prefijo y recogería, además del efecto del formato, un término atribuible a esa diferencia de longitud, sin forma de separarlos. La última posición, en cambio, desempeña el mismo papel funcional en ambos formatos, el de última posición antes de la generación condicionada a todo el contexto, con independencia de cuántos *tokens* de andamiaje la precedan.

Cálculo de la dirección de rechazo

Sean $\mathcal{D}_h$ y $\mathcal{D}_b$ los conjuntos de instrucciones dañinas y benignas en formato conversacional, con centroides $\boldsymbol{\mu}_h^{(l)}$ y $\boldsymbol{\mu}_b^{(l)}$ en la capa l. La dirección de rechazo es su diferencia normalizada,

$$\boldsymbol{r}^{(l)} = \boldsymbol{\mu}_h^{(l)} - \boldsymbol{\mu}_b^{(l)} = \frac{1}{n}\sum_{i=1}^{n}\left(\boldsymbol{x}_{h,i}^{(l)} - \boldsymbol{x}_{b,i}^{(l)}\right), \qquad \hat{\boldsymbol{r}}^{(l)} = \frac{\boldsymbol{r}^{(l)}}{\|\boldsymbol{r}^{(l)}\|}, \tag{3.5}$$

donde la segunda igualdad expresa la dirección como media de diferencias intra-par: cada par aporta el contraste entre dos instrucciones que comparten tema y vocabulario y difieren en la intención.

El eje que mejor separa dos clases, en el sentido del discriminante de Fisher, es $\boldsymbol{\Sigma}_W^{-1}(\boldsymbol{\mu}_h - \boldsymbol{\mu}_b)$, con $\boldsymbol{\Sigma}_W$ la covarianza dentro de las clases. Con $2n$ observaciones y $n \ll d$, la covarianza muestral tiene rango a lo sumo $2n-2$ y no es invertible. Regularizándola como $\hat{\boldsymbol{\Sigma}}_W + \lambda \boldsymbol{I}$, en el límite $\lambda \to \infty$ el discriminante se reduce exactamente a la diferencia de medias. Este estimador es, por tanto, el discriminante que renuncia a estimar la covarianza, que es lo que evita ajustar el ruido de la muestra cuando $n \ll d$.

La dirección es un estimador, no una cantidad conocida del modelo. Si $\boldsymbol{r}$ es la diferencia poblacional y $\boldsymbol{\Sigma}_\Delta$ la covarianza de las diferencias intra-par,

$$\mathbb{E}\left[\boldsymbol{r}^{(l)}\right] = \boldsymbol{r}, \qquad \mathbb{E}\left[\|\boldsymbol{r}^{(l)}\|^2\right] = \|\boldsymbol{r}\|^2 + \frac{\operatorname{tr}(\boldsymbol{\Sigma}_\Delta)}{n}. \tag{3.6}$$

El vector es insesgado, pero su norma está sesgada hacia arriba en un término que crece con la dimensión y decrece con el número de pares. Como la separación entre clases medida sobre los mismos datos que produjeron la dirección coincide exactamente con $\|\boldsymbol{r}^{(l)}\|$, esa separación hereda el sesgo, mientras que la condición agéntica, que no interviene en la estimación, no lo hereda. Es el sesgo de circularidad que el procedimiento corrige mediante validación cruzada.

Proyección y diferencia entre formatos

La proyección de una instrucción sobre la dirección de rechazo es

$$p^{(l)}(\boldsymbol{x}) = \boldsymbol{x}^{(l)} \cdot \hat{\boldsymbol{r}}^{(l)} = \|\boldsymbol{x}^{(l)}\| \cos\theta, \tag{3.7}$$

y constituye la medida central del estudio: un valor elevado indica que la representación de la instrucción está alineada con la dirección de rechazo. La segunda igualdad muestra que mezcla la orientación de la activación, que es lo que interesa, con su norma, que no. Como cada instrucción aparece en ambos formatos con texto idéntico, la unidad de análisis es la diferencia dentro del par:

$$\delta_{h,i}^{(l)} = p_{\text{chat}}^{(l)}(\boldsymbol{x}_{h,i}) - p_{\text{ag}}^{(l)}(\boldsymbol{x}_{h,i}), \qquad \Delta p_h^{(l)} = \frac{1}{n}\sum_{i=1}^{n} \delta_{h,i}^{(l)}, \tag{3.8}$$

con la definición análoga $\Delta p_b^{(l)}$ para las contrapartes benignas. Un valor $\Delta p_h^{(l)} > 0$ indica que la dirección de rechazo responde con menor intensidad en el formato agéntico. Con s_δ la desviación estándar de las diferencias intra-par, el estadístico de la prueba t pareada y el tamaño del efecto pareado son

$$t = \frac{\Delta p_h^{(l)}}{s_\delta/\sqrt{n}}, \qquad d_z = \frac{\Delta p_h^{(l)}}{s_\delta}, \qquad t = d_z\sqrt{n}, \tag{3.9}$$

de modo que d_z, y no t, es la cantidad comparable entre corpus de distinto tamaño.

Especificidad del efecto: el control benigno

La cantidad $\Delta p_h^{(l)}$, por sí sola, no distingue entre tres mecanismos: un debilitamiento del rechazo ante solicitudes dañinas, que es el que la investigación postula; un desplazamiento rígido que traslade toda representación a lo largo de $\hat{\boldsymbol{r}}^{(l)}$; y una contracción de escala que comprima todas las distancias. El brazo benigno resuelve la primera ambigüedad, pues atraviesa exactamente el mismo cambio de formato. La cantidad específica del contenido dañino es la interacción entre contenido y formato, acompañada de la fracción del efecto que el brazo benigno reproduce:

$$\Delta^2 p^{(l)} = \Delta p_h^{(l)} - \Delta p_b^{(l)}, \qquad \varphi^{(l)} = \frac{\Delta p_b^{(l)}}{\Delta p_h^{(l)}}. \tag{3.10}$$

Un desplazamiento rígido predice $\Delta^2 p^{(l)} \approx 0$ y $\varphi^{(l)} \approx 1$; un debilitamiento específico, $\Delta^2 p^{(l)} > 0$ con $\varphi^{(l)}$ pequeño; y $\varphi^{(l)} < 0$ indica que los dos brazos se desplazan en sentidos opuestos. La hipótesis de trabajo es $\Delta^2 p^{(l)} > 0$.

Invariancia de escala

La contracción de escala se resuelve expresando el efecto en unidades que la sobrevivan. Con S la separación entre las proyecciones medias de ambas clases dentro de un formato y s su desviación estándar agrupada, se definen la separación estandarizada y el factor de contracción,

$$d = \frac{S}{s}, \qquad \kappa = \frac{s_{\text{ag}}}{s_{\text{chat}}}. \tag{3.11}$$

Su papel se precisa con un caso límite. Si el formato se limitara a reescalar y desplazar las proyecciones, $p_{\text{ag}} = a\, p_{\text{chat}} + b$ con $a > 0$, se tendría

$$S_{\text{ag}} = a\, S_{\text{chat}}, \qquad d_{\text{ag}} = d_{\text{chat}}, \qquad \kappa = a, \tag{3.12}$$

y la separación cruda perdería una fracción $1 - a$, arbitrariamente grande, sin que se perdiera nada en d ni en el AUROC, que solo depende del orden. La parte de la pérdida que refleja capacidad discriminativa es, por tanto, la que sobrevive en d y en el AUROC. Por la misma razón, las unidades crudas no son comparables entre modelos, cuyos flujos residuales tienen normas distintas.

Dirección agéntica, rotación y monitor

Para saber si el formato agéntico conserva el eje conversacional, se estima por el mismo procedimiento una dirección propia de la condición agéntica, $\hat{\boldsymbol{w}}_{\mathrm{ag}}^{(l)}$, y se mide su coseno con $\hat{\boldsymbol{r}}^{(l)}$. Un coseno próximo a uno indica que el eje se conserva; uno próximo a cero, que la separación se ha reorganizado sobre un eje ortogonal. Como referencia, dos vectores al azar en $\mathbb{R}^d$ tienen un coseno típico del orden de $1/\sqrt{d}$, inferior a 0,016 en los modelos estudiados. Para valorar si la información reorganizada es aprovechable, se construye un monitor que marca una instrucción como dañina cuando su proyección sobre $\hat{\boldsymbol{w}}_{\mathrm{ag}}^{(l)}$ supera un umbral calibrado fuera de fold, y se resume su desempeño con la puntuación F_1 y la tasa de falsos positivos, esto es, la proporción de instrucciones benignas que bloquearía.

3.3.2. Procedimiento de análisis

El procedimiento aplica la formalización anterior en tres etapas. En la primera se extrae, para cada instrucción y cada capa del barrido, la activación del último *token*, manteniendo alineadas por identificador las cuatro variantes de cada par. En la segunda se estima la dirección de rechazo sobre el formato conversacional y se caracteriza su comportamiento por capa, verificando mediante análisis de componentes principales que el contraste dañino–benigno corresponde a un eje dominante de variación. En la tercera se calculan, por separado para cada brazo, el desplazamiento entre formatos, su interacción y su expresión en unidades crudas, estandarizadas y de rango, primero sobre el conjunto completo y después por grado de explicitud.

3.3.3. Implementación y reproducibilidad

El análisis se ejecutó sobre modelos de pesos abiertos descargados y ejecutados de manera local, sin acceso a servicios externos de inferencia. Los cuatro modelos se procesaron con la misma rutina de extracción, que registra el flujo residual correspondiente al último *token* de la instrucción en cada una de las capas del barrido. El barrido cubre en cada modelo un subconjunto de capas distribuido a lo largo de la red, cuyo tamaño se indica en la Tabla 3.3. Las cuatro variantes de cada par se procesan manteniendo su identificador común, condición de la que dependen todas las pruebas pareadas posteriores.

La rutina opera con un presupuesto de 4.096 *tokens* por instrucción y aborta la corrida si algún estímulo lo alcanza, en lugar de recortarlo en silencio. La razón se sigue de la Sección 3.3.1: la medida del estudio es la activación del último *token*, y sobre un texto recortado ese último *token* dejaría de ser el final de la petición, con lo que su cono de influencia ya no contendría la instrucción completa. Que una corrida termine certifica, por tanto, que toda activación analizada corresponde a una instrucción completa en ambos formatos.

Una precisión sobre el alcance de esta reproducibilidad. Los procedimientos de inferencia sobre modelos de gran escala en precisión reducida no son estrictamente deterministas, ya que el orden de las operaciones en punto flotante puede variar entre ejecuciones y entre configuraciones de *hardware*. Cabe esperar, por tanto, que una réplica reproduzca las magnitudes reportadas dentro del margen que los intervalos de confianza describen, y no cifra por cifra.

3.4. Estrategia de evaluación y validación

La evaluación se organiza en torno a dos controles que aseguran que los efectos observados sean atribuibles al mecanismo de rechazo y no a artefactos del diseño. El primero es el control benigno, formalizado en (3.10): el mismo tránsito de formato se aplica a las instrucciones benignas, de modo que solo la interacción entre contenido y formato se atribuye al rechazo. El segundo es la

separación entre los datos que estiman la dirección y los que evalúan su desempeño, que corrige el sesgo de circularidad descrito en (3.6).

3.4.1. Separabilidad entre clases y su estimación

Además de medir cuánto se reduce la proyección, interesa saber si la dirección conserva su capacidad de distinguir instrucciones dañinas de benignas. Para ello se emplea el AUROC, tomando la proyección como puntaje, que se estima contando las comparaciones correctamente ordenadas entre las n_h instrucciones dañinas y las n_b benignas:

$$\widehat{\mathrm{AUROC}} = \frac{1}{n_h n_b} \sum_{i=1}^{n_h} \sum_{j=1}^{n_b} \left[\mathbb{1}\big(p_{h,i} > p_{b,j}\big) + \tfrac{1}{2}\, \mathbb{1}\big(p_{h,i} = p_{b,j}\big) \right]. \tag{3.13}$$

Es la probabilidad de que una instrucción dañina tomada al azar proyecte más que una benigna: vale 1 con separación perfecta y 0,5 al azar. Por depender solo del orden, es invariante a cualquier cambio de escala. El gap de detección es la diferencia entre el AUROC conversacional y el agéntico, y responde a una pregunta distinta de la del gap de proyección: este mide la intensidad de la respuesta; aquel, si esa respuesta sigue bastando para separar las clases.

En el régimen $n \ll d$, cualquier etiquetado de la muestra es linealmente separable, de modo que un AUROC dentro de muestra próximo a la unidad es una propiedad de la geometría y no un hallazgo. Para obtener una estimación honesta, los pares se particionan en K subconjuntos y, para cada partición k, la dirección $\hat{\boldsymbol{r}}^{(l)}_{-k}$ se estima con los pares que no pertenecen a ella y se usa para puntuar, y solo a ellos, los pares retenidos:

$$\tilde{p}^{(l)}(\boldsymbol{x}_i) = \boldsymbol{x}_i^{(l)} \cdot \hat{\boldsymbol{r}}^{(l)}_{-k(i)}. \tag{3.14}$$

Las particiones se definen sobre pares y no sobre instrucciones sueltas, porque separar una instrucción dañina de su contraparte filtraría hacia la dirección el contraste que se pretende medir; y las cuatro variantes de un par retenido se puntúan con la misma dirección, lo que preserva el emparejamiento. La diferencia entre el valor dentro de muestra y el fuera de muestra se denomina

optimismo y se reporta de forma explícita. Como las estimaciones de una validación cruzada repetida comparten datos de entrenamiento, su varianza se corrige según Nadeau y Bengio (2003), multiplicándola por $1/J + n_{\text{eval}}/n_{\text{ent}}$, donde J es el número de estimaciones. Como referencia de contraste se repite el procedimiento completo con las etiquetas de daño barajadas, lo que estima el nivel de azar empírico, que no coincide necesariamente con 0,5.

3.4.2. Inferencia estadística sobre el diseño pareado

Dado que cada instrucción aparece en ambos formatos, las pruebas respetan el emparejamiento. La significancia de Δp_h se evalúa mediante una prueba de permutación de signos: bajo la hipótesis nula el signo de cada δ_i es intercambiable, y para B vectores de signos aleatorios $\varepsilon^{(b)} \in \{-1, +1\}^n$ se calcula

$$T^{(b)} = \frac{1}{n} \sum_{i=1}^{n} \varepsilon_i^{(b)} \delta_i, \qquad p = \frac{1 + \#\{b : T^{(b)} \geq \Delta p\}}{B + 1}. \tag{3.15}$$

Se acompaña de la prueba t pareada de (3.9) y de un intervalo de confianza por *bootstrap* pareado con corrección de sesgo y aceleración (BCa), que remuestrea pares completos y ajusta los percentiles cuando la distribución remuestreada es asimétrica. Se incluye, además, una prueba de signos exacta, que usa solo el sentido del cambio en cada par y ninguna magnitud, por lo que resulta insensible a la escala de las proyecciones y a cualquier reescalado de la dirección. No es, en cambio, independiente de la dirección sobre la que se proyecta, pues el signo de cada diferencia depende de ella; el resguardo frente a esa dependencia es que la dirección se estima fuera de muestra. Si k de los n pares decrecen, su valor p unilateral es $\sum_{j \geq k} \binom{n}{j} 2^{-n}$.

Como el análisis se repite en cada capa, la capa que maximiza el efecto no puede presentarse como un hallazgo independiente sin incurrir en selección múltiple. Por esa razón las afirmaciones del estudio no se apoyan en una capa aislada: el efecto se reporta a lo largo de todo el barrido, y lo que se interpreta es su presencia sostenida en el bloque profundo y su signo en los cuatro modelos. La capa de referencia sirve para reportar magnitudes, y cuando se contrasta una capa concreta la significancia se exige con corrección de Bonferroni sobre el número de capas evaluadas.

3.5. Consideraciones éticas

Una investigación sobre los mecanismos de seguridad de un modelo debe construir el estímulo que esos mecanismos deberían rechazar, y el conjunto de datos de este trabajo reúne, en consecuencia, instrucciones que solicitan acciones dañinas. Tres rasgos del diseño acotan el riesgo que ese material comporta. Las instrucciones describen la acción solicitada, pero no contienen los procedimientos, datos o artefactos que permitirían llevarla a cabo. Las herramientas que definen la condición agéntica son simuladas y no están conectadas a ningún sistema, de modo que ninguna petición puede materializarse en un efecto real. Y el estudio no analiza las respuestas del modelo para obtener contenido dañino, sino sus activaciones internas.

El trabajo es, además, diagnóstico: el modelo no se reentrena ni se interviene para suprimir su capacidad de rechazo, y no se genera por tanto un modelo desalineado como subproducto. Los resultados describen dónde se degrada un mecanismo de seguridad, información de doble uso; se considera que el balance favorece su divulgación, porque el fallo ya está documentado en el plano conductual y porque una defensa basada en representaciones internas solo puede construirse a partir de este tipo de diagnóstico. Los modelos se emplean conforme a sus licencias, que contemplan la investigación en seguridad, y el estudio no involucra sujetos humanos ni datos personales: los nombres y cuentas que aparecen en las instrucciones son ficticios.

Capítulo 4

Resultados y evaluación

Este capítulo presenta lo que arrojaron las corridas del procedimiento. La Sección 4.1 expone los hallazgos en el orden que el argumento requiere. Delimita primero el alcance de las corridas y establece después la línea base conversacional, sin la cual no habría nada cuya transformación medir. Presenta a continuación el resultado central, el desplazamiento entre formatos, junto con su especificidad respecto del brazo benigno, y lo somete a la pregunta que decide su interpretación: cuánto de su magnitud sobrevive al expresarlo en unidades invariantes a la escala. Examina por último dos consecuencias, su comportamiento según el grado de explicitud y la reorientación del eje sobre el que se codifica la peligrosidad. La Sección 4.2 verifica la estabilidad de la estimación frente al sesgo de circularidad. En todos los casos la medida es la proyección del último *token* de la instrucción, cuya elección se justifica en la Sección 3.3.1.

La interpretación de estos resultados, junto con sus implicaciones y el alcance de su validez, se desarrolla en el Capítulo 5.

4.1. Resultados, análisis e interpretación

4.1.1. Alcance de las corridas

Los resultados provienen de cuatro corridas completas del procedimiento sobre tres familias de modelos distintas. La Tabla 4.1 resume su configuración.

Tres familias con recetas de entrenamiento y escalas distintas, entre siete y setenta mil millones de parámetros, permiten distinguir lo propio del fenómeno de lo propio de una arquitectura.

Modelo	Familia	Capas	Pares	Capa de referencia
Mistral-7B-Instruct-v0.3	Mistral	16 de 32	96	18
Qwen3-8B	Qwen	18 de 36	96	22
Qwen3-32B	Qwen	32 de 64	96	46
Llama-3.3-70B-Instruct	Llama	20 de 80	42	56

Tabla 4.1: Configuración de las corridas reportadas. La corrida sobre Llama-3.3-70B emplea el corpus de 42 pares; las tres restantes, el corpus completo de 96. La réplica de este modelo sobre el corpus completo se encuentra en ejecución y no se reporta aquí.

En cada modelo el análisis se realiza capa por capa y la capa de referencia es aquella en la que el procedimiento maximiza el desplazamiento medido.

Por consistencia, las cifras de Llama-3.3-70B se reportan siempre identificando el corpus sobre el que fueron obtenidas, y no se agregan con las demás en ninguna comparación que requiera un corpus común.

4.1.2. Línea base en formato conversacional

Antes de comparar formatos es necesario establecer que, en el formato conversacional, la intención dañina está codificada de manera linealmente accesible. La línea base se construye con una sonda lineal validada mediante diez repeticiones de validación cruzada en cinco particiones, con el estandarizador, la sonda y la dirección reajustados dentro de cada partición. La Tabla 4.2 recoge el resultado en la capa de referencia de cada modelo.

Modelo	Sonda (VC)	Etiquetas barajadas	Margen
Mistral-7B	0,955 ± 0,030	0,516	0,439
Qwen3-8B	0,957 ± 0,027	0,541	0,416
Qwen3-32B	0,962 ± 0,027	0,537	0,425
Llama-3.3-70B *	0,947 ± 0,053	0,470	0,477

Tabla 4.2: Separabilidad dañino–benigno en formato conversacional, en la capa de referencia de cada modelo. El control con etiquetas barajadas estima el nivel de azar empírico para el tamaño de muestra y la dimensión del problema. *Corpus de 42 pares.

En los cuatro modelos la sonda validada supera el nivel de azar empírico por más de cuatro décimas de AUROC. El control con etiquetas barajadas resulta indispensable para leer esa cifra:

el azar a este tamaño de muestra y dimensión no es 0,500 sino un valor que oscila entre 0,470 y 0,541 según el modelo, y solo midiéndolo puede saberse cuál es el suelo que el valor observado debe superar.

Conviene registrar que el AUROC calculado dentro de muestra vale exactamente 1,000 en todas las capas evaluadas de los cuatro modelos, incluidas aquellas donde el valor validado desciende marcadamente. Con $2n$ puntos en d dimensiones y $n \ll d$ cualquier etiquetado es linealmente separable, de modo que esa saturación es una propiedad de la geometría y no un hallazgo sobre los datos. Ninguna afirmación de este capítulo se apoya en cifras dentro de muestra.

La Figura 4.1 muestra cómo evoluciona la accesibilidad lineal con la profundidad, fenómeno descrito por Alain y Bengio (2017) que aquí se reproduce: el AUROC validado asciende desde las capas iniciales hasta un máximo extenso en el bloque intermedio y desciende después hacia la salida.

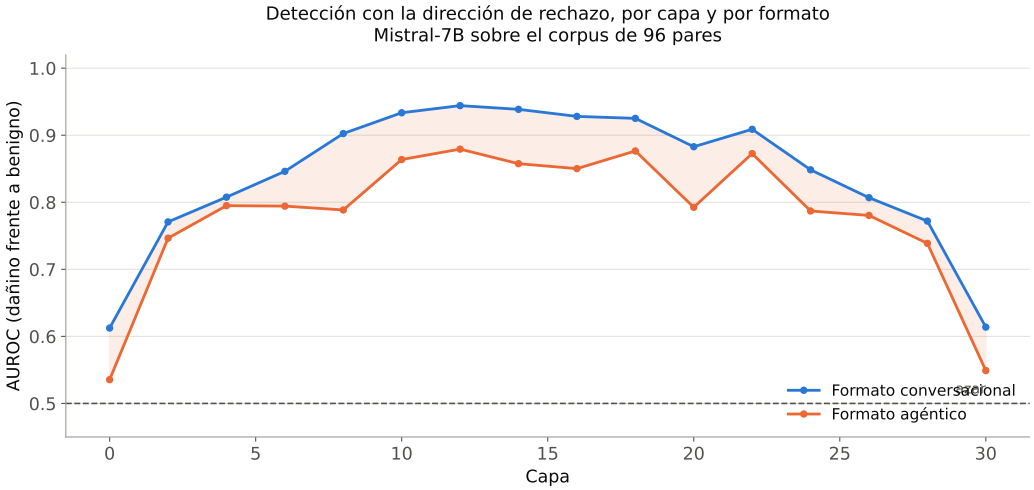


Figura 4.1: Capacidad de discriminación de la dirección de rechazo por capa y por formato, en Mistral-7B sobre el corpus de 96 pares. La curva agéntica discurre por debajo de la conversacional en todo el bloque profundo sin aproximarse al azar.

4.1.3. El desplazamiento entre formatos y su especificidad

El resultado central es el gap de proyección Δp_h, esto es la diferencia entre la proyección media que las instrucciones dañinas alcanzan sobre la dirección de rechazo en formato conversacional y la que esas mismas instrucciones alcanzan en formato agéntico. Cuantifica cuánto se alinea la representación de una instrucción dañina con la dirección de rechazo en cada formato y en qué medida esa alineación disminuye cuando la única diferencia es la disponibilidad de herramientas. Conviene precisar su alcance. La cantidad Δp_h es una medida geométrica sobre la representación interna y no una lectura de la conducta del modelo, de modo que un valor alto no demuestra por sí solo que el modelo reconozca el peligro ni uno bajo que lo pase por alto. Lo que la proyección sostiene se circunscribe a su capacidad de separar instrucciones dañinas de benignas, que se cuantifica mediante el AUROC; su correspondencia con el rechazo efectivo del modelo es una cuestión distinta que no se deduce de la proyección.

Considerado de forma aislada, Δp_h no basta para sostener la interpretación que la pregunta requiere, pues un desplazamiento común a toda representación produciría el mismo valor. La cantidad que responde a la pregunta es la interacción entre contenido y formato, $\Delta^2 p = \Delta p_h - \Delta p_b$, definida en (3.10), acompañada de la fracción del efecto que el brazo benigno reproduce, $\varphi = \Delta p_b / \Delta p_h$.

Modelo	Δp_h	Δp_b	$\Delta^2 p$	**IC 95 % de** $\Delta^2 p$	φ
Mistral-7B	2,33	−1,01	3,34	[2,89; 3,77]	−43,4 %
Qwen3-8B	42,27	−0,12	42,39	[37,17; 47,36]	−0,3 %
Qwen3-32B	71,90	11,96	59,94	[53,13; 66,41]	16,6 %
Llama-3.3-70B *	5,74	−3,23	8,97	[7,48; 10,36]	−56,3 %

Tabla 4.3: Desplazamiento entre formatos en la capa de referencia de cada modelo. Δp_h y Δp_b corresponden al brazo dañino y al benigno; $\Delta^2 p$ es la interacción. Las cantidades se expresan en unidades crudas de proyección y no son comparables entre modelos. *Corpus de 42 pares.

En los cuatro modelos la interacción es positiva, su intervalo de confianza excluye el cero y la prueba de permutación arroja $p < 10^{-4}$. El tamaño del efecto de la interacción se sitúa entre 2,16 y 2,67 en unidades estandarizadas.

El patrón de φ merece atención porque distingue dos regímenes. En Mistral-7B y en Llama-3.3-70B la fracción común es negativa, lo que indica que los dos brazos se desplazan en sentidos opuestos: las instrucciones dañinas pierden proyección mientras las benignas la ganan, de modo que la interacción supera al efecto principal y las dos clases convergen sobre el eje que las distinguía. En Qwen3-8B la fracción común es prácticamente nula, esto es, el brazo benigno no se mueve en absoluto y la totalidad del desplazamiento es atribuible al contenido dañino. En Qwen3-32B la fracción es positiva pero pequeña, de manera que apenas una sexta parte del efecto es común a ambos brazos. Los tres casos son compatibles con la hipótesis de trabajo y ninguno con un desplazamiento rígido, que exigiría $\varphi \approx 1$ y $\Delta^2 p \approx 0$. La Figura 4.2 muestra esa convergencia en la capa de referencia de Mistral-7B.

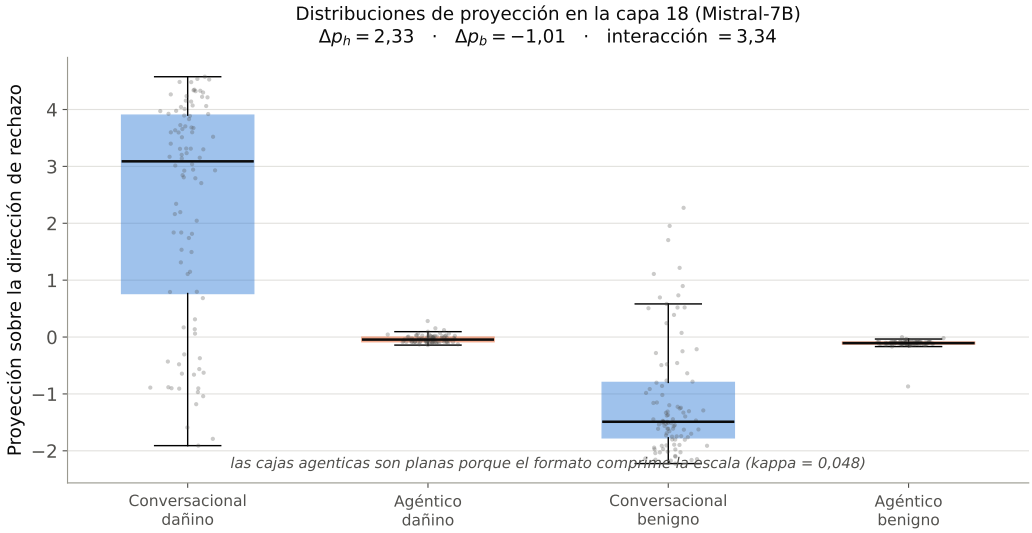


Figura 4.2: Distribuciones de proyección sobre la dirección de rechazo en la capa de referencia de Mistral-7B. Las instrucciones dañinas pierden proyección al pasar al formato agéntico y las benignas la ganan, de modo que ambas nubes convergen sobre el eje que las separaba.

El fenómeno no se limita a la capa de referencia. La Figura 4.3 muestra el desplazamiento por capa separado por brazo: la interacción es positiva a lo largo del bloque profundo y crece de forma sostenida con la profundidad. Esa regularidad es informativa por sí misma, pues un desplazamiento atribuible a la longitud del estímulo o al mensaje de sistema no tendría razón

para acentuarse con la profundidad, mientras que un mecanismo que opera sobre la representación semántica de la petición sí la tiene.

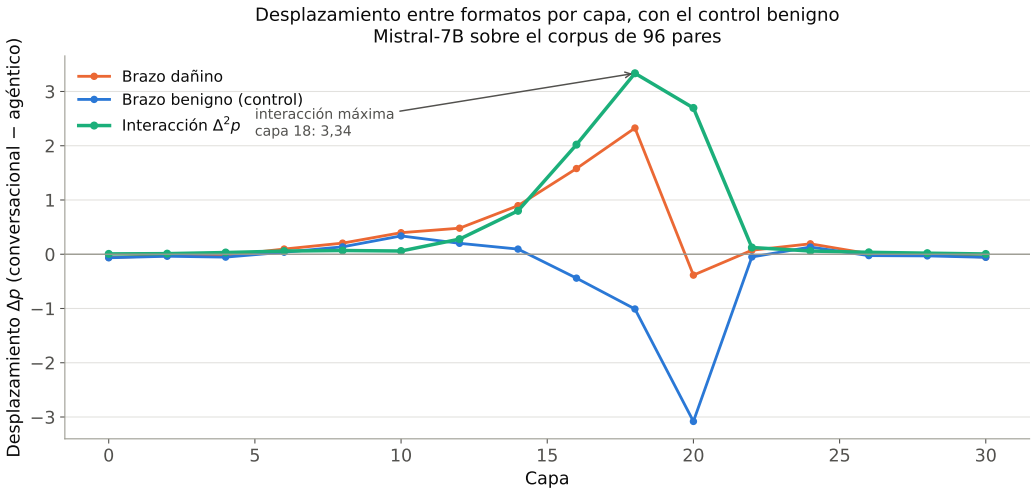


Figura 4.3: Desplazamiento entre formatos por capa, separado por brazo, en Mistral-7B. El brazo dañino pierde proyección y el benigno la gana, de manera que la interacción excede al efecto principal en toda la red profunda.

4.1.4. Escala del efecto

Expresado en distintas unidades, el efecto admite lecturas muy distintas en magnitud, y la discrepancia entre ellas constituye por sí misma un resultado. La separación entre clases dentro de cada formato se reporta en tres unidades: cruda, estandarizada por la desviación típica agrupada, y de rango mediante el AUROC. El cociente $\kappa = s_{\text{ag}}/s_{\text{chat}}$ de (3.11) mide directamente la contracción de escala, y el caso límite de (3.12) indica cómo leer la discrepancia entre unidades: una contracción pura reduce la separación cruda sin alterar la estandarizada ni el AUROC. La Tabla 4.4 recoge las tres lecturas.

La contracción de escala es pronunciada en los cuatro modelos y extrema en los dos más pequeños, donde la desviación típica de las proyecciones en formato agéntico es menos de una vigésima parte de la conversacional. Esto implica que la pérdida medida en unidades crudas, que alcanza el 97,8 % en Mistral-7B y el 99,6 % en Qwen3-8B, sobreestima gravemente la pérdida de

Modelo	d_{chat}	d_{ag}	**Pérdida en d**	**AUROC**	κ
Mistral-7B	2,20	1,04	52,9 %	0,925 → 0,877	0,048
Qwen3-8B	2,35	0,76	67,6 %	0,936 → 0,746	0,012
Qwen3-32B	2,58	1,77	31,6 %	0,950 → 0,915	0,293
Llama-3.3-70B *	2,93	1,83	37,5 %	0,969 → 0,905	0,306

Tabla 4.4: El efecto expresado en unidades invariantes a la escala. La pérdida en d y el AUROC son comparables entre modelos; las unidades crudas de la Tabla 4.3 no lo son. *Corpus de 42 pares.

separabilidad: buena parte de esa caída es un cambio de unidades y no un cambio de capacidad discriminativa. Las cifras que corresponden al efecto son la pérdida estandarizada y la de AUROC.

La distancia entre ambas lecturas es la información que el reporte en tres unidades permite recuperar. En Qwen3-32B, por ejemplo, la separación cruda cae un 80,0 % mientras la estandarizada cae un 31,6 % y el AUROC apenas 0,035. Interpretar la primera cifra como pérdida de detección sería un error de unidades.

La Figura 4.4 contrasta ambas lecturas en los tres modelos evaluados sobre el corpus completo. En unidades crudas el efecto abarca un rango de treinta y un veces entre el menor y el mayor; en unidades estandarizadas los tres se sitúan entre 2,16 y 2,52.

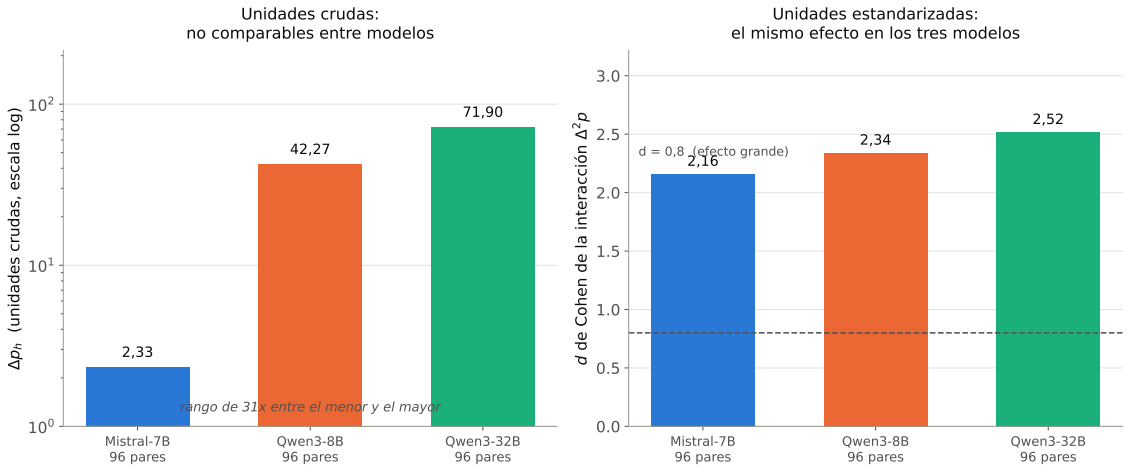


Figura 4.4: El mismo efecto medido en dos unidades, en los tres modelos evaluados sobre el corpus de 96 pares. El panel izquierdo emplea escala logarítmica. La comparación entre modelos solo es legítima en el panel derecho.

4.1.5. Comportamiento según el grado de explicitud

El análisis por estrato responde al cuarto objetivo específico. El corpus de 96 pares distribuye las instrucciones dañinas en 42 explícitas, 24 contextuales y 30 de apariencia legítima, tamaños que permiten estimaciones comparables entre los tres niveles.

Modelo	**Estrato**	*n*	**AUROC chat**	**AUROC agente**	**Pérdida**
Mistral-7B	Explícito	42	0,969	0,885	0,084
	Contextual	24	0,891	0,845	0,045
	Apariencia legítima	30	0,927	0,886	0,041
Qwen3-8B	Explícito	42	0,988	0,740	0,248
	Contextual	24	0,924	0,785	0,139
	Apariencia legítima	30	0,913	0,746	0,168
Qwen3-32B	Explícito	42	0,991	0,973	0,018
	Contextual	24	0,915	0,835	0,080
	Apariencia legítima	30	0,947	0,926	0,021

Tabla 4.5: Capacidad de detección por grado de explicitud de la intención dañina, en la capa de referencia de cada modelo, sobre el corpus de 96 pares.

Dos lecturas se desprenden de la Tabla 4.5. La primera es que la detección se mantiene en formato agéntico en valores iguales o superiores a 0,74 en los nueve estratos evaluados, y superiores a 0,84 en cinco de ellos: la dirección conserva poder discriminativo incluso ante intención encubierta, con un margen menor que en el formato conversacional.

La segunda es que la ordenación entre estratos no se conserva entre modelos. En Mistral-7B y en Qwen3-8B el estrato explícito es el que más margen pierde, mientras que en Qwen3-32B esa posición la ocupa el estrato contextual y el explícito apenas se degrada. Disponer de tres modelos permite afirmar lo que con uno solo únicamente podía insinuarse: el efecto del formato está presente en los tres niveles de explicitud, pero el orden en que los afecta depende del modelo y no constituye una propiedad general del fenómeno.

Una regularidad sí se sostiene en los tres modelos. El estrato explícito parte siempre del AUROC conversacional más alto, entre 0,969 y 0,991, mientras que los dos estratos encubiertos parten de valores más bajos. Una lectura compatible con estas cifras es que el formato agéntico ero-

siona sobre todo el margen allí donde era más amplio, mientras que en las instrucciones encubiertas ese margen ya era estrecho en el formato conversacional.

La Figura 4.5 contrasta las dos cantidades. Medido por el tamaño del efecto del gap de proyección, el orden entre estratos sí se conserva en los tres modelos: el estrato explícito presenta siempre el efecto mayor y el de apariencia legítima el menor. Medido por la pérdida de AUROC, en cambio, ese orden se rompe. Las dos cantidades responden a preguntas distintas, la intensidad de la respuesta y la capacidad de discriminación, y el contraste entre ambas ordenaciones es la evidencia más directa de que no deben confundirse.

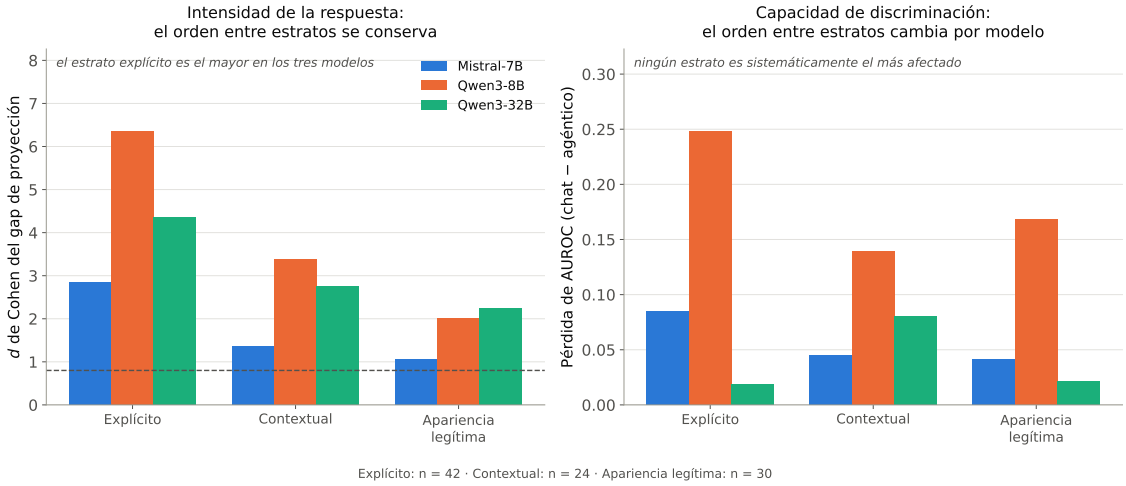


Figura 4.5: Comportamiento por grado de explicitud en los tres modelos evaluados sobre el corpus de 96 pares. El panel izquierdo mide la intensidad de la respuesta mediante el tamaño del efecto del gap de proyección; el derecho, la capacidad de discriminación mediante la pérdida de AUROC.

4.1.6. Reorientación del eje

El desplazamiento de la proyección viene acompañado de un cambio de eje. Al estimar por diferencia de medias una dirección propia del formato agéntico, denotada $\boldsymbol{w}_{\text{ag}}$, y compararla con la dirección de rechazo conversacional, el coseno entre ambas resulta próximo a cero en la capa de referencia de los cuatro modelos: 0,088 en Mistral-7B, 0,011 en Qwen3-8B, 0,051 en Qwen3-32B y 0,051 en Llama-3.3-70B. En todos los casos el barrido alcanza valores aún menores en alguna capa del bloque profundo. La Figura 4.6 traza ese descenso por profundidad relativa.

En las capas donde el efecto de formato es más intenso, por tanto, la dirección que separa lo dañino de lo benigno en contexto agéntico es prácticamente ortogonal a la dirección de rechazo conversacional. La información no desaparece: se reorganiza sobre un eje distinto.

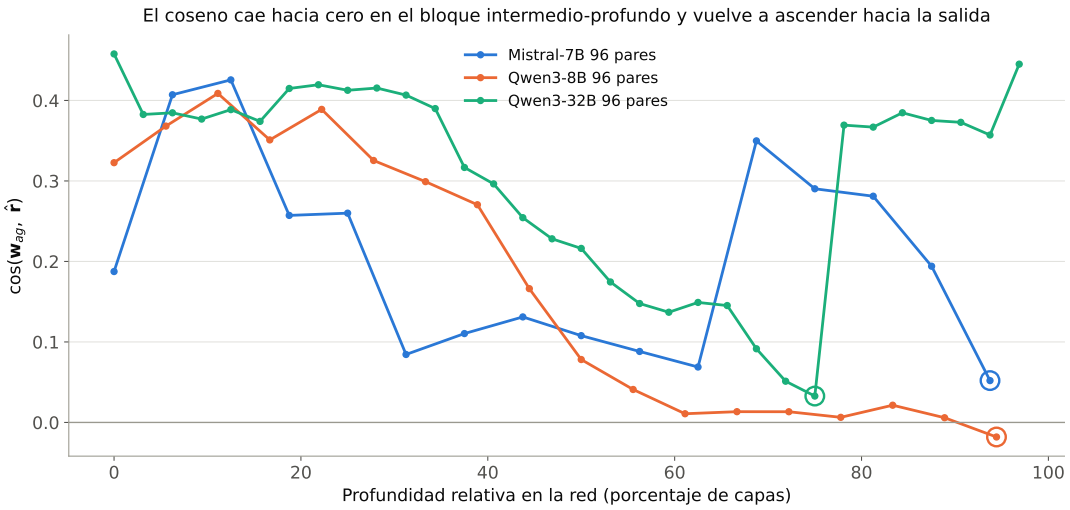


Figura 4.6: Coseno entre la dirección estimada en formato agéntico y la dirección de rechazo conversacional, por profundidad relativa en la red. El círculo marca el mínimo de cada curva. Las tres familias recorren el mismo descenso hacia el bloque intermedio-profundo.

Que esa información siga siendo recuperable lo confirma el desempeño fuera de fold de un monitor construido sobre $\boldsymbol{w}_{\text{ag}}$. En Qwen3-32B alcanza una puntuación F_1 de 0,873 con una tasa de falsos positivos de 0,156; en Mistral-7B y Qwen3-8B, F_1 de 0,749 y 0,750 con tasas de falsos positivos de 0,271 y 0,354. El AUROC fuera de fold de la dirección agéntica se sitúa entre 0,830 y 0,941, frente al valor de 1,000 sobre la muestra completa que la geometría del problema garantiza de antemano.

4.2. Evaluación y validación

Los apartados anteriores presentaron los hallazgos. El que sigue los somete al control definido en la Sección 3.4 para el sesgo de circularidad, esto es, verifica que ninguno de ellos sea un artefacto de estimar la dirección con las mismas activaciones que después se proyectan. La replicación del fenómeno entre modelos, que en una corrida única requeriría un apartado propio,

está presente en cada uno de los apartados anteriores, pues todas las cifras se reportan para las cuatro corridas.

4.2.1. Estabilidad de la estimación

La corrección por circularidad verifica que el desplazamiento no sea un artefacto de estimar la dirección sobre las mismas activaciones que después se proyectan. Para cada partición la dirección se reestima excluyendo los pares evaluados, y la diferencia entre ambas estimaciones cuantifica el sesgo. La Tabla 4.6 reporta ambas estimaciones.

Modelo	Δp_h **ingenuo**	Δp_h **fuera de muestra**	**Sesgo**	**Pares que decrecen**
Mistral-7B	2,33	2,26	2,8 %	77/96
Qwen3-8B	42,27	41,74	1,3 %	93/96
Qwen3-32B	71,90	70,23	2,4 %	94/96
Llama-3.3-70B *	5,74	5,50	4,4 %	36/42

Tabla 4.6: Corrección por circularidad en la capa de referencia, con validación cruzada en cinco particiones definidas sobre pares. El sesgo se expresa como porcentaje del valor corregido. *Corpus de 42 pares.

El sesgo se mantiene por debajo del 5 % del efecto en los cuatro modelos, y por debajo del 3 % en los tres evaluados sobre el corpus completo. Los tres modelos evaluados sobre el corpus completo presentan sesgos menores que la corrida sobre 42 pares, lo que es compatible con (3.6), cuyo término de ruido decrece con el número de pares. La comparación no aísla ese factor, sin embargo, porque la corrida sobre 42 pares corresponde además a un modelo distinto; la réplica de Llama-3.3-70B sobre el corpus completo permitirá separar ambos efectos.

La prueba de signos emplea únicamente el sentido del cambio dentro de cada par y ninguna magnitud, por lo que es insensible a la escala de las proyecciones y a cualquier reescalado de la dirección. No es, en cambio, independiente de la dirección sobre la que se proyecta, pues el signo de cada diferencia depende de ella; el resguardo frente a esa dependencia es que la dirección se estima fuera de muestra, excluyendo de su cálculo los pares que después se evalúan. Con esa salvedad, la

prueba confirma el resultado en los tres modelos evaluados sobre 96 pares: entre el 80 % y el 98 % de los pares decrecen, con $p < 10^{-9}$ en los tres casos.

Capítulo 5

Discusión

5.1. Síntesis de los hallazgos

5.2. El modo de fallo que describen los resultados

5.3. Implicaciones

5.4. Limitaciones y alcance de validez

Glosario de notación

Se reúnen a continuación la notación y las medidas que aparecen en el capítulo de resultados, de modo que puedan consultarse sin volver sobre la formalización.

Cono de influencia ($C(i)$)

Conjunto de *tokens* de la secuencia que pueden alterar la representación de la posición i. Por la máscara causal es $\{1, \ldots, i\}$, de modo que solo el último *token* tiene como cono la instrucción completa. Es la razón por la que el estudio mide en esa posición.

Capa de referencia

Capa de cada modelo en la que el procedimiento maximiza el desplazamiento medido y sobre la que se reportan las cifras principales. Depende del modelo: 18 en Mistral-7B, 22 en Qwen3-8B, 46 en Qwen3-32B y 56 en Llama-3.3-70B.

Índice de Jaccard (J)

Proporción de términos compartidos entre la rama dañina y la benigna de un par, sobre el total de términos distintos que usan ambas. Mide la simetría léxica del pareado: vale uno si las dos ramas usan el mismo vocabulario y cero si no comparten ninguno.

Proyección (p)

Medida geométrica de cuánto se alinea la representación de una instrucción con la dirección de rechazo. Un valor alto indica mayor alineación con ese eje, no que el modelo reconozca el peligro; su capacidad de separar instrucciones dañinas de benignas se cuantifica aparte, mediante el AUROC.

Gap de proyección (Δp_h)

Diferencia entre la proyección media de las instrucciones dañinas en formato conversacional y la de esas mismas instrucciones en formato agéntico. Mide en qué medida *disminuye* esa alineación al cambiar de formato, y es el resultado central de este trabajo.

Interacción o diferencia en diferencias ($\Delta^2 p$)

Diferencia entre el desplazamiento del brazo dañino y el del benigno. Es la parte del efecto específica del contenido dañino.

Fracción común (φ)

Proporción del desplazamiento dañino que el brazo benigno reproduce. Un valor negativo indica que los dos brazos se desplazan en sentidos opuestos.

AUROC

Probabilidad de que, tomadas al azar una instrucción dañina y una benigna, la dañina proyecte más que la benigna. Un valor de 1 indica separación perfecta y uno de 0,5 una separación equivalente al azar.

Gap de detección (ΔAUROC)

Diferencia entre el AUROC del formato conversacional y el del agéntico. Cuenta la proporción de comparaciones dañino–benigno que el formato conversacional ordena correctamente y el agéntico deja de ordenar correctamente. Es una cantidad distinta del gap de proyección y responde a otra pregunta: aquel mide intensidad de la respuesta, este mide capacidad de discriminación.

Contracción de escala (κ)

Cociente entre la desviación estándar de las proyecciones en formato agéntico y la observada en formato conversacional. Cuantifica qué parte de una pérdida medida en unidades crudas corresponde a un cambio de unidades.

$w_{\mathbf{ag}}$

Dirección estimada por diferencia de medias dentro del formato agéntico. Su coseno con la dirección de rechazo conversacional mide cuánto ha rotado el eje sobre el que el modelo codifica la peligrosidad.

Referencias

Alain, G., & Bengio, Y. (2017). Understanding intermediate layers using linear classifier probes. *International Conference on Learning Representations (ICLR), Workshop Track*. https://arxiv.org/abs/1610.01644

Andriushchenko, M., Souly, A., Dziemian, M., Duenas, D., Lin, M., Wang, J., Hendrycks, D., Zou, A., Kolter, Z., Fredrikson, M., Winsor, E., Wynne, J., Gal, Y., & Davies, X. (2024). AgentHarm: A benchmark for measuring harmfulness of LLM agents. https://arxiv.org/abs/2410.09024

Arditi, A., Obeso, O., Syed, A., Paleka, D., Panickssery, N., Gurnee, W., & Nanda, N. (2024). Refusal in language models is mediated by a single direction. *Advances in Neural Information Processing Systems (NeurIPS 2024)*. https://arxiv.org/abs/2406.11717

Bai, Y., Kadavath, S., Kundu, S., Askell, A., Kernion, J., Jones, A., Chen, A., Goldie, A., Mirhoseini, A., McKinnon, C., Chen, C., Olsson, C., Olah, C., Hernandez, D., Drain, D., Ganguli, D., Li, D., Tran-Johnson, E., Perez, E., . . . Kaplan, J. (2022). Constitutional AI: Harmlessness from AI feedback. https://arxiv.org/abs/2212.08073

Durán, R., Moreno, A., Adasme, S., Rovira, S., Jordán, V., & Poveda, L. (2025). *Índice Latinoamericano de Inteligencia Artificial (ILIA) 2025* (Documentos de Proyectos N.º LC/TS.2025/68) (Coordinadores). Comisión Económica para América Latina y el Caribe (CEPAL) y Centro Nacional de Inteligencia Artificial (CENIA). https://www.cepal.org/es/publicaciones/82514-indice-latinoamericano-inteligencia-artificial-ilia-2025

Gravitee. (2026). *State of AI agent security 2026 report: When adoption outpaces control*. Consultado el 1 de septiembre de 2026, desde https://www.gravitee.io/blog/state-of-ai-agent-security-2026-report-when-adoption-outpaces-control

Greenblatt, R., Denison, C., Wright, B., Roger, F., MacDiarmid, M., Marks, S., Treutlein, J., Belonax, T., Chen, J., Duvenaud, D., Khan, A., Michael, J., Mindermann, S., Perez, E.,

Petrini, L., Uesato, J., Kaplan, J., Shlegeris, B., Bowman, S. R., & Hubinger, E. (2024). Alignment faking in large language models. https://arxiv.org/abs/2412.14093

Lermen, S., Dziemian, M., & Pimpale, G. (2024). Applying refusal-vector ablation to Llama 3.1 70B agents. https://arxiv.org/abs/2410.10871

miniOrange. (2026). *AI agent security risks: What enterprises need to know in 2026*. Consultado el 1 de septiembre de 2026, desde https://www.miniorange.com/blog/ai-agent-security-risks/

Nadeau, C., & Bengio, Y. (2003). Inference for the generalization error. *Machine Learning*, *52*(3), 239-281. https://doi.org/10.1023/A:1024068626366

Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J., & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems (NeurIPS 2022)*. https://arxiv.org/abs/2203.02155

Park, K., Choe, Y. J., & Veitch, V. (2024). The linear representation hypothesis and the geometry of large language models. *International Conference on Machine Learning (ICML)*. https://arxiv.org/abs/2311.03658

Pinto, L. (2026). Present but rescaled: Chat-to-agent transfer of additive activation steering. https://arxiv.org/abs/2607.09156

Templeton, A., Conerly, T., Marcus, J., Lindsey, J., Bricken, T., Chen, B., Pearce, A., Citro, C., Ameisen, E., Jones, A., Cunningham, H., Turner, N. L., McDougall, C., MacDiarmid, M., Freeman, C. D., Sumers, T. R., Rees, E., Batson, J., Jermyn, A., . . . Henighan, T. (2024). *Scaling monosemanticity: Extracting interpretable features from Claude 3 Sonnet*. Transformer Circuits Thread. Consultado el 1 de septiembre de 2026, desde https://transformer-circuits.pub/2024/scaling-monosemanticity/

Zhong, V., & Li, Q. (2026). Refusal lives downstream of persona in chat models [ICML 2026 Mechanistic Interpretability Workshop]. https://arxiv.org/abs/2606.26161

Zou, A., Phan, L., Chen, S., Campbell, J., Guo, P., Ren, R., Pan, A., Yin, X., Mazeika, M., Dombrowski, A.-K., Goel, S., Li, N., Byun, M. J., Wang, Z., Mallen, A., Basart, S., Koyejo, S., Song, D., Fredrikson, M., . . . Hendrycks, D. (2023). Representation engineering: A top-down approach to AI transparency. https://arxiv.org/abs/2310.01405