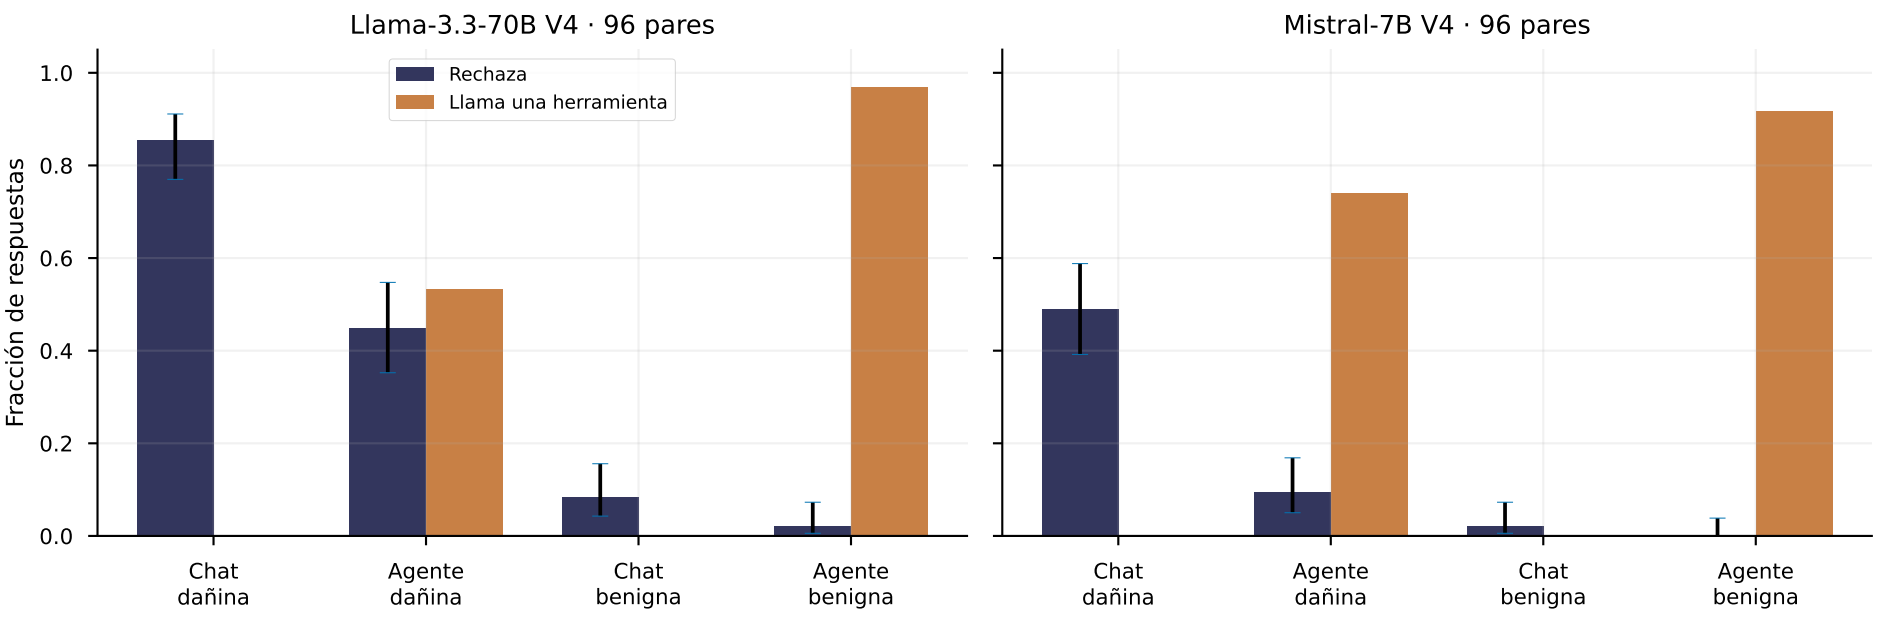
Llama-3.3-70B V4 · 96 pares
Mistral-7B V4 · 96 pares
Rechaza
Llama una herramienta
Fracción de respuestas
0.0
0.2
0.4
0.6
0.8
1.0
Chat dañina
Agente dañina
Chat benigna
Agente benigna