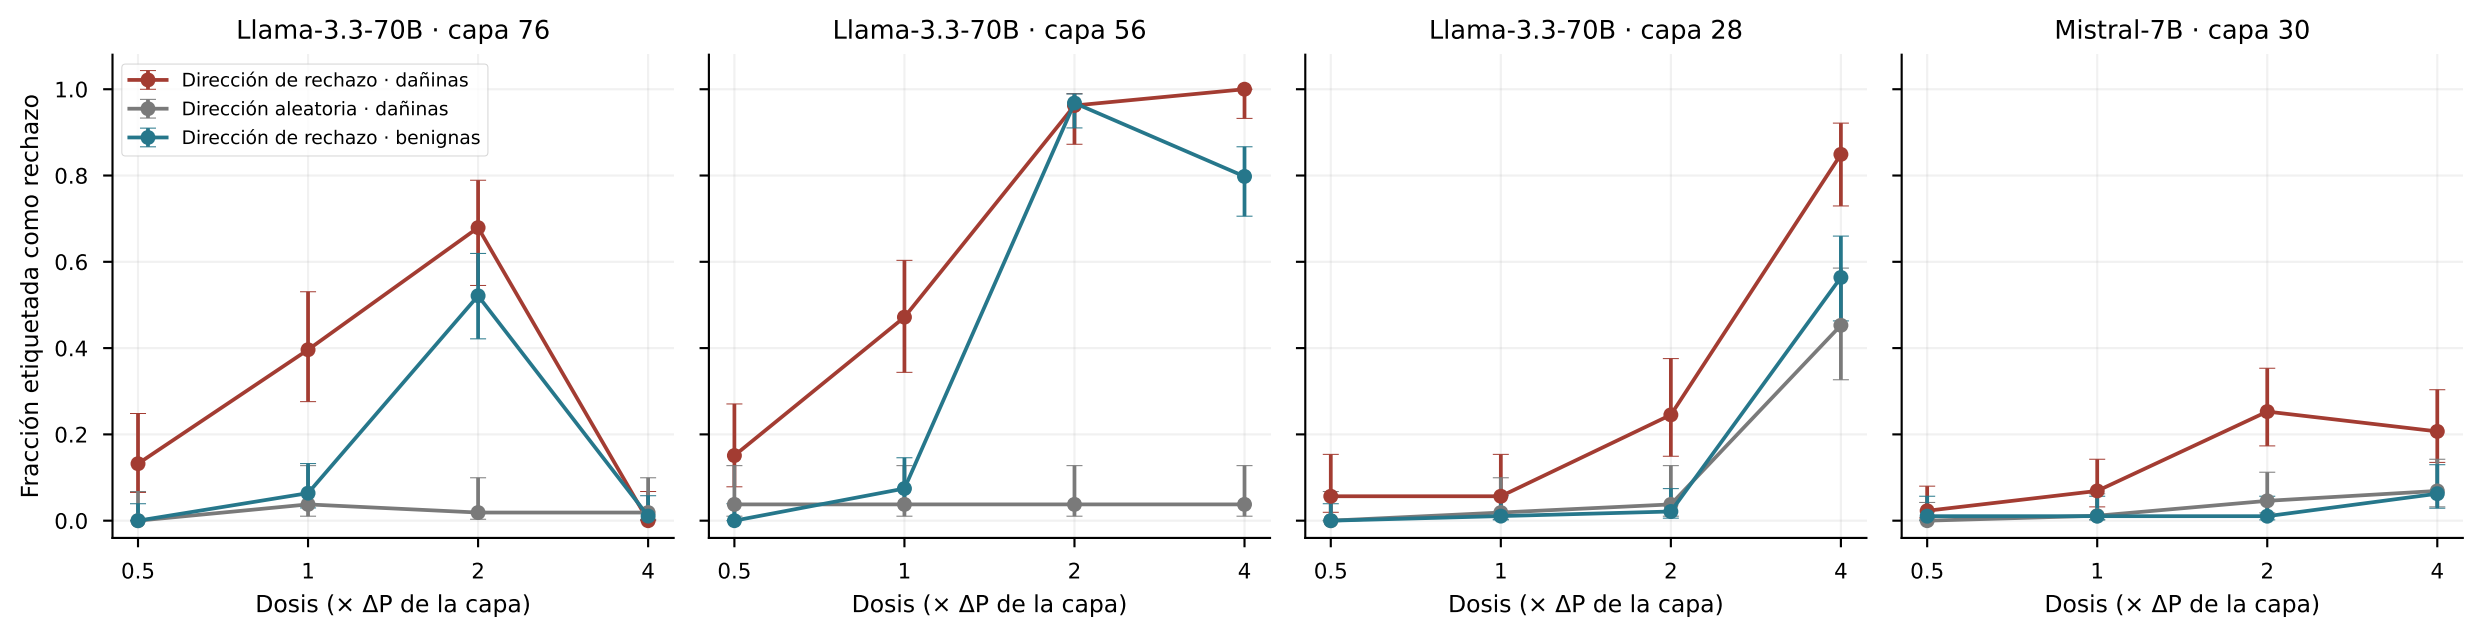
Llama-3.3-70B · capa 76
Llama-3.3-70B · capa 56
Llama-3.3-70B · capa 28
Mistral-7B · capa 30
Dirección de rechazo · dañinas
Dirección aleatoria · dañinas
Dirección de rechazo · benignas
Fracción etiquetada como rechazo
0.0
0.2
0.4
0.6
0.8
1.0
0.5
1
2
4
Dosis (× ΔP de la capa)