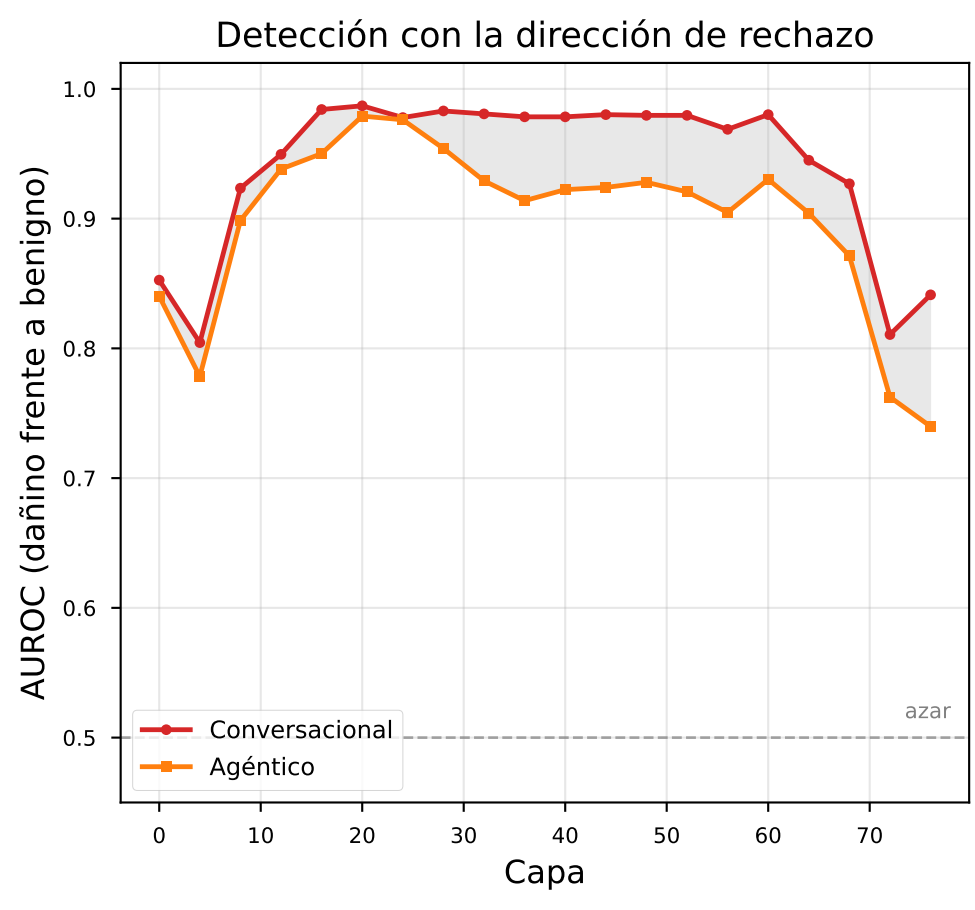
Detección con la dirección de rechazo
AUROC (dañino frente a benigno)
1.0
0.9
0.8
0.7
0.6
0.5
azar
Conversacional
Agéntico
0
10
20
30
40
50
60
70
Capa

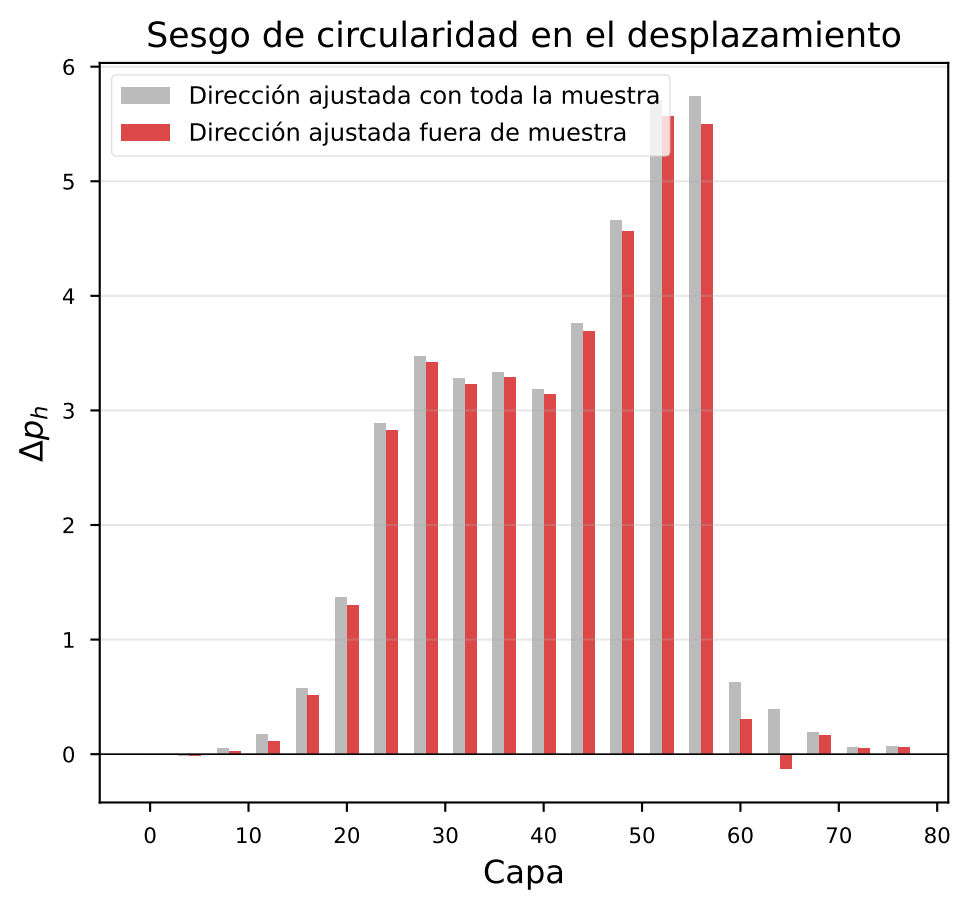
Sesgo de circularidad en el desplazamiento
Dirección ajustada con toda la muestra
Dirección ajustada fuera de muestra
Δp_h
6
5
4
3
2
1
0
0
10
20
30
40
50
60
70
80
Capa