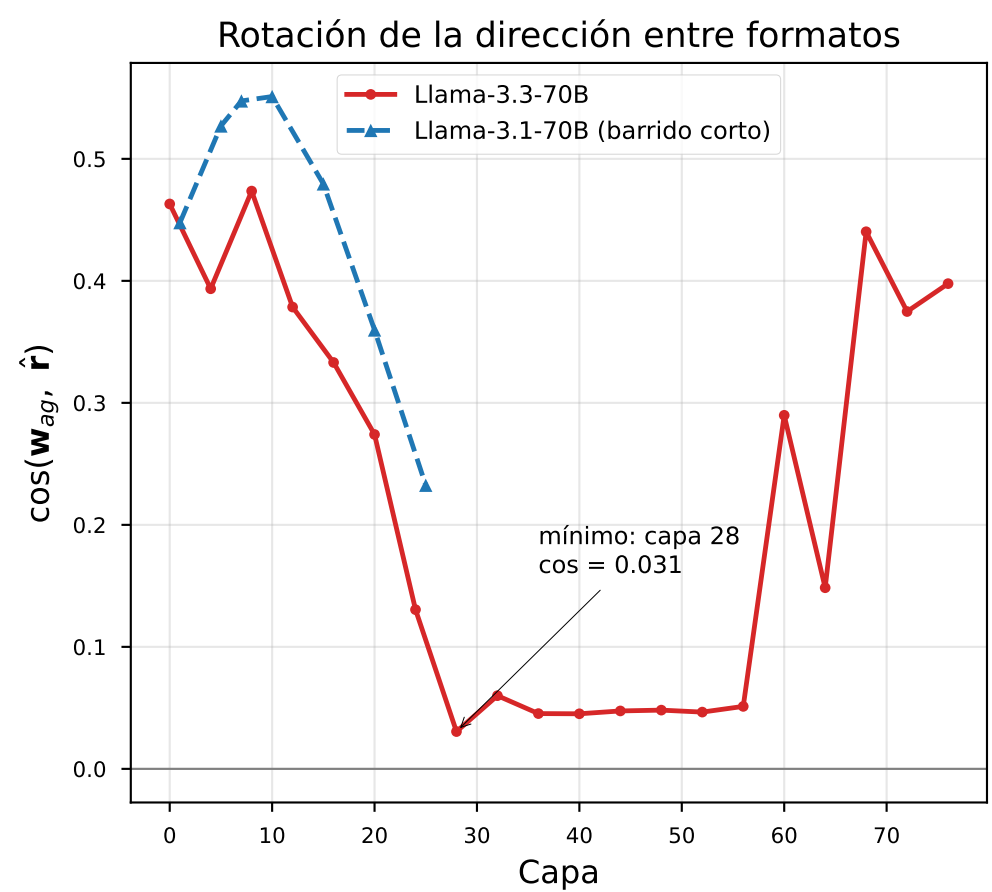
Rotación de la dirección entre formatos
Llama-3.3-70B
Llama-3.1-70B (barrido corto)
mínimo: capa 28
cos = 0.031
cos(w_ag, r̂)
Capa

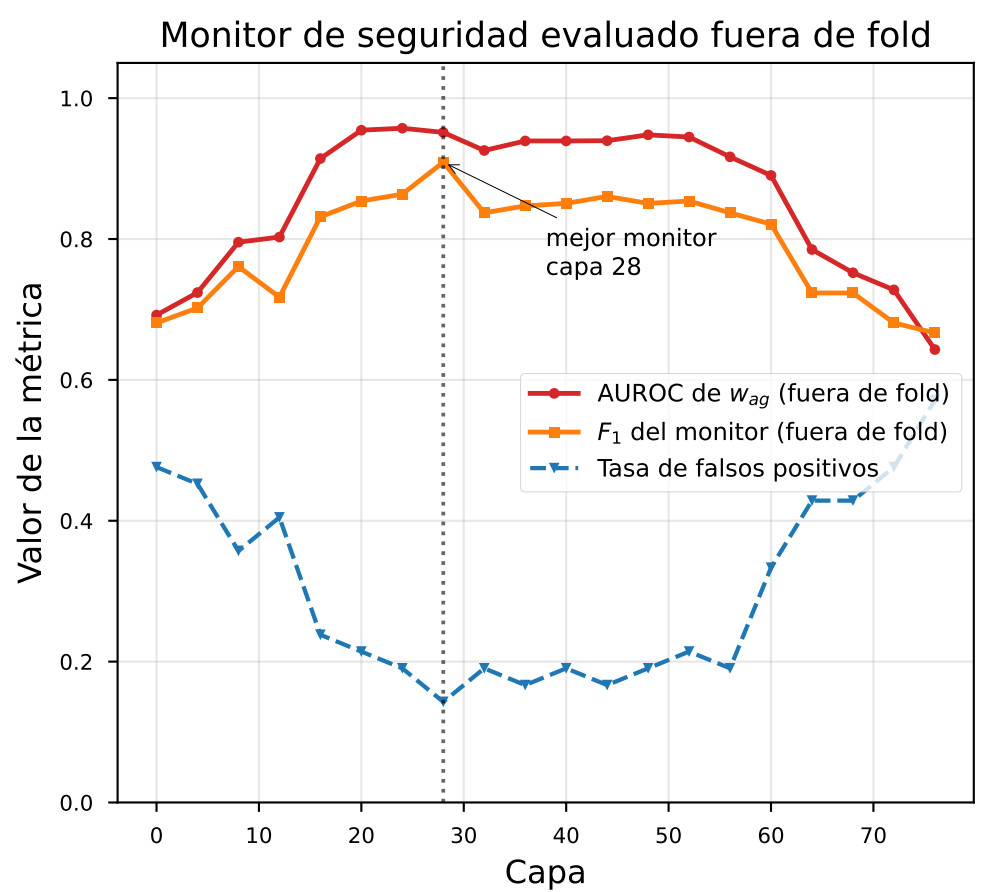
Monitor de seguridad evaluado fuera de fold
mejor monitor
capa 28
AUROC de w_ag (fuera de fold)
F1 del monitor (fuera de fold)
Tasa de falsos positivos
Valor de la métrica
Capa